

Probabilités GM3

Ioana CIOTIR

2021 - 2022

Table des matières

1	Espaces probabilisés	3
1.1	Paradoxe de Bertrand	3
1.2	Rappel de théorie de la mesure	4
1.3	Théorie des probabilités	5
2	Variables aléatoires	7
2.1	Loi d'une variable aléatoire	8
2.2	Fonction de répartition d'une variable aléatoire	11
2.3	Espérance probabiliste	13
2.4	Moments des variables aléatoires	15
2.5	Variance	18
3	Vecteurs aléatoires	22
3.1	Rappels d'intégration	22
3.2	Vecteurs aléatoires	24
3.3	Fonction d'un vecteur aléatoire	26
4	Indépendance	27
5	Espérance conditionnelle	31
6	Somme de deux variables aléatoires	34
6.1	Convolution de mesures et de fonctions	34
6.2	Loi d'une somme de variables aléatoires indépendantes à densité	35
7	Convergences de variables aléatoires	37
7.1	Convergence presque sûre	37
7.2	Convergence en norme L^p	37
7.3	Convergence en loi	38
7.4	Convergence en probabilité	38
7.5	Relations entre les types de convergence	38

8	Lois des grandes nombres	41
8.1	Version faible de la LGN	41
8.2	Version forte de la LGN	44
8.2.1	Estimateurs	44
8.2.2	Méthode de Monte-Carlo	45
8.3	Version L^1 de la LGN	45
9	Théorème limite centrale	47
9.1	Fonction caractéristique	47
9.2	Variables et vecteurs gaussiens	49
9.3	Théorème limite centrale	50
10	Temps d'arrêt	53

Chapitre 1

Espaces probabilisés

1.1 Paradoxe de Bertrand

Soit un cercle de rayon 20 cm et un autre cercle concentrique de rayon 10 cm. On dessine une corde dans le grand cercle (**au hasard**). On veut calculer la probabilité qu'elle intersecte le petit cercle.

Solution 1 *Chaque corde est uniquement déterminée par la position de son centre (à une rotation prêt).*

On calcule

$$\mathbb{P} = \frac{\text{Aire du petit cercle}}{\text{Aire du grand cercle}} = \frac{100\pi}{400\pi} = \frac{1}{4}.$$

Solution 2 *Si on suppose les cordes verticales (à une rotation prêt) alors les cas favorables sont quand le milieu de la corde se trouve sur le diamètre horizontal du petit cercle*

$$\mathbb{P} = \frac{\text{Diamètre du petit cercle}}{\text{Diamètre du grand cercle}} = \frac{20}{40} = \frac{1}{2}.$$

Solution 3 *On suppose que toutes les cordes ont (à une rotation prêt) une extrémité dans le point le plus à gauche du grand cercle. On note l'angle formé par la corde et l'horizontale par θ .*

Le nombre de cas possible est entre $(-\frac{\pi}{2}, \frac{\pi}{2})$ donc π .

Le nombre de cas favorable est entre $(-\frac{\pi}{6}, \frac{\pi}{6})$ donc $\frac{\pi}{3}$.

$$\mathbb{P} = \frac{\frac{\pi}{3}}{\pi} = \frac{1}{3}.$$

Il faut donc correctement définir et comprendre le mot "hasard" et il faut bien choisir l'espece de probabilité.

1.2 Rappel de théorie de la mesure

Soit Ω un ensemble et $\mathcal{P}(\Omega)$ l'ensemble des parties de Ω .

Définition 4 On appelle $\mathcal{A} \subset \mathcal{P}(\Omega)$ une **tribu** (ou **une σ -algèbre**) si elle vérifie :

- $\Omega \in \mathcal{A}$
- Si $A \in \mathcal{A}$ alors $A^c \in \mathcal{A}$
- Pour toute famille dénombrable $\{A_n\}_{n \geq 1} \subset \mathcal{A}$ on a $\bigcup_{n \geq 1} A_n \in \mathcal{A}$.

On appelle **ensemble mesurable** tout élément de la σ -algèbre \mathcal{A} .

Un espace Ω muni d'une σ -algèbre s'appelle **espace mesurable**. (Not. (Ω, \mathcal{A})).

Exemple 5 Les ensembles suivants sont des tribus (des σ -algèbres)

- $\mathcal{A}_1 = \{\emptyset, \Omega\}$
- $\mathcal{A}_2 = \mathcal{P}(\Omega)$.

Proposition 6 Soit Ω muni d'une σ -algèbre \mathcal{A} . On a les propriétés suivantes

- Si $A, B \in \mathcal{A}$ alors $A \cap B \in \mathcal{A}$
- $\emptyset \in \mathcal{A}$.

Définition 7 Soit $G \subset \mathcal{P}(\Omega)$. On dit que $\mathcal{A} \subset \mathcal{P}(\Omega)$ est une **tribu (σ -algèbre) engendrée par G** si elle est la plus petite tribu (σ -algèbre) qui contient tous les éléments de G .

Définition 8 Soit Ω un espace topologique (muni d'une famille d'ouverts). On appelle **tribu borélienne** la tribu engendrée par tous les ouverts de Ω . (Not. $\mathcal{B}(\Omega)$).

Définition 9 Une application $f : (\Omega, \mathcal{A}) \rightarrow (\tilde{\Omega}, \tilde{\mathcal{A}})$ est dite **mesurable** si

$$\forall \tilde{A} \in \tilde{\mathcal{A}} \text{ on a } f^{-1}(\tilde{A}) \in \mathcal{A}.$$

Définition 10 Une *mesure* μ sur (Ω, \mathcal{A}) est une application

$$\mu : \mathcal{A} \rightarrow [0, +\infty]$$

telle que

- $\mu(\emptyset) = 0$
- si $\{A_n\}_{n \geq 1}$ est une famille dénombrable d'ensembles de \mathcal{A} , deux à deux disjoints, alors

$$\mu \left(\bigcup_{n \geq 1} A_n \right) = \sum_{n=1}^{\infty} \mu(A_n).$$

Exemple 11 La mesure de Lebesgue sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ qui généralise la notion de longueur des intervalles

$$\lambda([a, b]) = b - a \quad \text{et} \quad \lambda(x + A) = \lambda(A).$$

Proposition 12 Soit une mesure μ sur (Ω, \mathcal{A}) . Alors on a les propriétés suivantes

- i) $\mu(A^c) = \mu(\Omega) - \mu(A)$ (si $\mu(\Omega) < \infty$)
- ii) $\mu(A \setminus B) = \mu(A) - \mu(A \cap B)$
- iii) $A \subset B \implies \mu(A) \leq \mu(B)$
- iv) $\mu(A \cup B) = \mu(A) + \mu(B) - \mu(A \cap B)$.

Le triplet $(\Omega, \mathcal{A}, \mu)$ est appelé un espace mesuré (espace mesurable muni d'une mesure).

1.3 Théorie des probabilités

Définition 13 On appelle *mesure de probabilité* ou probabilité une mesure note \mathbb{P} pour qui la masse totale est 1 ($\mathbb{P}(\Omega) = 1$).

Un espace mesuré dont la mesure est une probabilité est appelé *espace de probabilité*. Not. $(\Omega, \mathcal{A}, \mathbb{P})$.

Un ensemble $A \in \mathcal{A}$ est appelé évènement.

Exemple 14 (Espace de probabilité discrète)

Soit $\Omega = \{\omega_1, \omega_2, \dots, \omega_N\}$ et une famille de valeurs positives $\{p_1, p_2, \dots, p_N\}$

telles que $\sum_{i=1}^N p_i = 1$.

On peut définir une probabilité \mathbb{P} donnée par

$$\mathbb{P}(\omega_i) = p_i, \quad \forall i \in \{1, 2, \dots, N\}.$$

Pour un ensemble $A = \{\omega_1, \omega_3, \omega_7\}$ on a $\mathbb{P}(A) = p_1 + p_3 + p_7$.

Exemple 15 (*Espace de probabilité avec densité*)

Soit $\Omega = \mathbb{R}$ et $\mathcal{B}(\mathbb{R})$ la tribu borélienne.

On appelle densité une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ telle que $f \geq 0$, f est intégrable et $\int_{\mathbb{R}} f(x) dx = 1$.

On peut définir une probabilité \mathbb{P} donnée par

$$\mathbb{P}(A) = \int_A f(x) dx, \quad \forall A \in \mathcal{B}(\mathbb{R}).$$

Remarque 16 *Les deux cas précédents sont des cas particuliers. On ne peut pas trouver une densité pour toute mesure de probabilité.*

Chapitre 2

Variables aléatoires

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité.

Définition 17 On appelle variable aléatoire (notée v.a.) toute application mesurable

$$X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

Plus précisément X est une variable aléatoire si et seulement si elle vérifie

$$X^{-1}(B) \in \mathcal{F}, \quad \forall B \in \mathcal{B}(\mathbb{R}).$$

Définition 18 Soit $X : \Omega \rightarrow \mathbb{R}$ une variable aléatoire. On définit

$$\mathcal{U}(X) = \{X^{-1}(B) : \forall B \in \mathcal{B}(\mathbb{R})\}$$

une σ -algèbre qui est engendré par X .

Remarque 19 On voit que :

- 1) C'est la plus petite σ -algèbre par rapport à qui la variable aléatoire est mesurable.
- 2) $\mathcal{U}(X)$ contient toute les informations sur X .
- 3) Si on considère $Y = \Phi(X)$ pour Φ une fonction C^2 , alors Y est aussi une fonction $\mathcal{U}(X)$ -mesurable. Réciproquement, si Y est $\mathcal{U}(X)$ -mesurable, alors il existe une fonction Φ telle que $Y = \Phi(X)$.

Définition 20 On appelle $X : [0, T] \times \Omega \rightarrow \mathbb{R}$ un processus stochastique si

$$\begin{aligned} t &\longmapsto X(t, \omega) \text{ est continue} \\ \omega &\longmapsto X(t, \omega) \text{ est une variable aléatoire.} \end{aligned}$$

On note par $\{X_t, \quad t \in [0, T]\}$.

2.1 Loi d'une variable aléatoire

Définition 21 Soit $X : \Omega \rightarrow \mathbb{R}$ une variable aléatoire. On appelle loi de la variable aléatoire X une mesure \mathbb{P}_X sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ définie par

$$\begin{aligned}\mathbb{P}_X & : \mathcal{B}(\mathbb{R}) \rightarrow [0, 1] \\ \mathbb{P}_X(A) & = \mathbb{P}(X \in A) \\ & = \mathbb{P}(X^{-1}(A)) \\ & = \mathbb{P}(\{\omega \in \Omega : X(\omega) \in A\}), \quad \forall A \in \mathcal{B}(\mathbb{R}).\end{aligned}$$

Remarque 22 \mathbb{P}_X est une mesure de probabilité définie sur $\mathcal{B}(\mathbb{R})$.

Loi d'une variable aléatoire discrète

On rappelle que une variable aléatoire discrète une variable qui a des valeurs dans un ensemble au plus dénombrable.

Soit X une variable aléatoire discrète.

Pour chaque $a \in \mathbb{R}$, on considère la mesure de Dirac en a qui est définie par

$$\delta_a(A) = \begin{cases} 1, & \text{si } a \in A \\ 0, & \text{sinon.} \end{cases}$$

On a la loi de X définie par

$$\mathbb{P}_X(A) = \sum_{x \in X(\Omega)} \mathbb{P}(X = x) \delta_x(A).$$

Exemple 23 Soit $X : \Omega \rightarrow \{x_1, x_2, x_3\}$ et $A = \{x_1, x_3\}$. On a

$$\begin{aligned}\mathbb{P}_X(A) & = \mathbb{P}(X = x_1) \delta_{x_1}(A) + \mathbb{P}(X = x_2) \delta_{x_2}(A) + \mathbb{P}(X = x_3) \delta_{x_3}(A) \\ & = \mathbb{P}(X = x_1) + \mathbb{P}(X = x_3).\end{aligned}$$

On voit que les ensembles $\{X = x_1\}$ et $\{X = x_3\}$ sont disjointe.

Si $X : \Omega \rightarrow \{x_1, x_2, x_3, \dots, x_n\}$ et $\mathbb{P}(X = x_i) = p_i$, $\forall i = \overline{1, n}$. Alors

$$\mathbb{P}_X(A) = \sum_{i=1}^n p_i \delta_{x_i}(A).$$

Intégrale de Lebesgue

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité et $f : \Omega \rightarrow \mathbb{R}$ une fonction mesurable, donc une fonction qui vérifie $f^{-1}(B) \in \mathcal{F}$, $\forall B \in \mathcal{B}(\mathbb{R})$.

On définit

$$\int_{\Omega} f(\omega) d\mathbb{P}(\omega)$$

– *Etape 1*

Soit

$$f(x) = \sum_{i=1}^k c_i I_{A_i}(x)$$

une fonction simple (escalier) où $\{c_i\}_{i=1}^k \subset \mathbb{R}$ et $\{A_i\}_{i=1}^k \subset \mathcal{F}$.
Pour une fonction simple et positive, on peut définir

$$\int_{\Omega} f(\omega) d\mathbb{P}(\omega) = \sum_{i=1}^k c_i \mathbb{P}(A_i).$$

– *Etape 2*

Soit f une fonction positive mesurable. On a toujours une suite de fonctions simples positives telles que

$$f_n(\omega) \rightarrow f(\omega), \quad \forall \omega \in \Omega.$$

On peut définir l'intégrale par

$$\int_{\Omega} f(\omega) d\mathbb{P}(\omega) = \lim_{n \rightarrow \infty} \int_{\Omega} f_n(x) d\mathbb{P}(\omega).$$

L'intégrale est bien définie car

- 1) On peut toujours construire une telle suite $\{f_n\}$
- 2) Si on a deux suites $\{f_n\}$ et $\{g_n\}$ qui vérifient

$$f_n(\omega) \rightarrow f(\omega), \quad \forall \omega \in \Omega.$$

$$g_n(\omega) \rightarrow f(\omega), \quad \forall \omega \in \Omega.$$

alors

$$\lim_{n \rightarrow \infty} \int_{\Omega} f_n(x) d\mathbb{P}(\omega) = \lim_{n \rightarrow \infty} \int_{\Omega} g_n(x) d\mathbb{P}(\omega).$$

– *Etape 3*

Soit f une fonction mesurable. On peut l'écrire comme

$$f = f^+ - f^-$$

où

$$f^+(x) = \begin{cases} f(x), & \text{si } f(x) \geq 0 \\ 0, & \text{sinon} \end{cases} \quad f^-(x) = \begin{cases} -f(x), & \text{si } f(x) \leq 0 \\ 0, & \text{sinon} \end{cases}.$$

Comme f^+ et f^- sont positives et mesurables, on peut définir

$$\int_{\Omega} f(\omega) d\mathbb{P}(\omega) = \int_{\Omega} f^+(\omega) d\mathbb{P}(\omega) - \int_{\Omega} f^-(\omega) d\mathbb{P}(\omega).$$

On dit qu'une fonction f est **Lebesgue intégrable** si et seulement si

$$\int_{\Omega} f(\omega) d\mathbb{P}(\omega) < \infty.$$

Proposition 24 *L'intégrale de Lebesgue a les propriétés suivantes*

- 1) $\int_A f(\omega) d\mathbb{P}(\omega) = \int_{\Omega} f(\omega) 1_A(\omega) d\mathbb{P}(\omega).$
- 2) Si $f = g$ presque partout, alors $\int_{\Omega} f(\omega) d\mathbb{P}(\omega) = \int_{\Omega} g(\omega) d\mathbb{P}(\omega).$
- 3) Si $f \geq 0$ alors $\int_{\Omega} f(\omega) d\mathbb{P}(\omega) \geq 0.$
- 4) $\int_{\Omega} (f(\omega) + g(\omega)) d\mathbb{P}(\omega) = \int_{\Omega} f(\omega) d\mathbb{P}(\omega) + \int_{\Omega} g(\omega) d\mathbb{P}(\omega)$
- 5) $\int_A f(\omega) d\mathbb{P}(\omega) + \int_B f(\omega) d\mathbb{P}(\omega) = \int_{A \cup B} f(\omega) d\mathbb{P}(\omega),$ pour $\forall A, B \in \mathcal{F}$
tels que $A \cap B = \emptyset$

Loi d'une variable aléatoire continue

Définition 25 Soit (Ω, \mathcal{F}) un espace mesurable muni de deux mesures μ et σ . On dit que μ est absolument continue par rapport à σ si, pour tout $A \in \mathcal{F}$ on a

$$\sigma(A) = 0 \implies \mu(A) = 0.$$

On note $\mu \ll \sigma$.

Théorème 26 Si on a deux mesures μ et σ telles que $\mu \ll \sigma$, alors il existe une fonction $f : \Omega \rightarrow \mathbb{R}$ mesurable, telle que pour tout $A \in \mathcal{F}$ on a que

$$\mu(A) = \int_A f(x) d\sigma(x).$$

On note

$$d\mu = f d\sigma.$$

Remarque 27 La fonction f s'appelle la densité de μ par rapport à σ et on a le lien suivant entre les intégrales

$$\int_A g(x) d\mu(x) = \int_A g(x) f(x) d\sigma(x).$$

Soit $f : \mathbb{R} \rightarrow \mathbb{R}$ une fonction densité (positive, intégrable et avec $\int_{\mathbb{R}} f(x) dx = 1$).

Alors on peut définir une mesure de probabilité sur $\mathcal{B}(\mathbb{R})$ définie par

$$\mathbb{P}(A) = \int_A f(x) dx, \quad \forall A \subset \mathcal{B}(\mathbb{R}).$$

Définition 28 Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité et X une variable aléatoire telle que

$$X : \Omega \rightarrow \mathbb{R}.$$

On dit que X est une variable aléatoire "à densité" s'il existe une fonction $f : \mathbb{R} \rightarrow \mathbb{R}_+$ qui vérifie les propriétés d'une densité (intégrable, et telle que $\int_{\mathbb{R}} f(x) dx = 1$) telle que la loi de X peut être écrite comme suit

$$\mathbb{P}_X(A) = \int_A f(x) dx, \quad \forall A \subset \mathcal{B}(\mathbb{R}).$$

Remarque 29 Il y a des variables aléatoires qui ne sont pas "à densité". Une variable aléatoire est "à densité" seulement si sa loi est absolument continue par rapport à la mesure de Lebesgue.

2.2 Fonction de répartition d'une variable aléatoire

Définition 30 Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité et $X : \Omega \rightarrow \mathbb{R}$ une variable aléatoire. On appelle fonction de répartition de X la fonction

$$F_X : \mathbb{R} \rightarrow [0, 1]$$

définie par

$$F_X(x) = \mathbb{P}(X \leq x) = \mathbb{P}_X([-\infty, x]).$$

Proposition 31 (Propriétés de la fonction de répartition)

- 1) F_X est une fonction croissante
- 2) $\lim_{x \rightarrow -\infty} F_X(x) = 0$ et $\lim_{x \rightarrow \infty} F_X(x) = 1$
- 3) F_X est continue à droite et admet une limite à gauche

$$\begin{aligned} F_X(a^+) &= \lim_{x \rightarrow a, x \geq a} F_X(x) = F_X(a) \\ F_X(a^-) &= \lim_{x \rightarrow a, x \leq a} F_X(x). \end{aligned}$$

$$4) \mathbb{P}(a < X \leq b) = F_X(b) - F_X(a)$$

Démonstration.

4)

$$\begin{aligned}(X \leq b) &= ((X \leq b) \cap (X > a)) \cup ((X \leq b) \cap (X \leq a)) \\ &= ((X \leq b) \cap (X > a)) \cup (X \leq a)\end{aligned}$$

$$\begin{aligned}F_X(b) &= \mathbb{P}((X \leq b) \cap (X > a)) + \mathbb{P}(X \leq a) \\ &= \mathbb{P}((X \leq b) \cap (X > a)) + F_X(a)\end{aligned}$$

Donc

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a).$$

■

Proposition 32 Si X est une variable aléatoire de densité f , sa fonction de répartition F_X vérifie

- 1) $F_X(x) = \int_{-\infty}^x f(t) dt, \quad \forall x \in \mathbb{R}$
- 2) F_X est continue sur \mathbb{R}
- 3) Si f est continue, alors F_X est dérivable et $F'_X = f$.

Démonstration.

- 1) On a par la définition de la fonction de répartition que

$$F_X(x) = \mathbb{P}(X \leq x) = \mathbb{P}(X^{-1}([-\infty, x])) = \mathbb{P}_X([-\infty, x]).$$

Comme X est une variable aléatoire de densité f , on a

$$\mathbb{P}_X([-\infty, x]) = \int_{]-\infty, x]} f(x) dx = \int_{-\infty}^x f(x) dx.$$

- 2) On fixe un point a quelconque. Comme F_X est continue à droite, car fonction de répartition, il reste à montrer la continuité à gauche.

Soit $(a_n)_n$ une suite croissante qui converge vers a . Il faut vérifier que

$$\lim_{n \rightarrow \infty} F_X(a_n) = F_X(a).$$

En effet

$$F_X(a) - F_X(a_n) = \int_{a_n}^a f(x) dx = \int_{\mathbb{R}} f(x) 1_{[a_n, a]}(x) dx.$$

Comme $|f(x) 1_{[a_n, a]}(x)| \leq |f(x)|$ qui est intégrable et $f(x) 1_{[a_n, a]}(x) \rightarrow 0$ pour $\forall x \in \mathbb{R}$, on peut appliquer le théorème de convergence dominée de Lebesgue et on obtient que

$$\int_{\mathbb{R}} f(x) 1_{[a_n, a]}(x) dx \rightarrow 0$$

et donc

$$F_X(a) - F_X(a_n) \rightarrow 0$$

ce qui implique la continuité.

■

Remarque 33 Si X est une variable aléatoire de densité f , on a, pour tout interval $[a, b]$, que

$$\begin{aligned} F_X(b) &= \mathbb{P}(X \in]-\infty, b]) \\ &= \mathbb{P}(X \in]-\infty, a] \cup]a, b]) \\ &= F_X(a) + \mathbb{P}(X \in]a, b]). \end{aligned}$$

On obtient donc

$$\mathbb{P}(X \in]a, b]) = F_X(b) - F_X(a) = \int_a^b f(t) dt.$$

2.3 Espérance probabiliste

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité.

Rappel

Si on a $X : \Omega \rightarrow \{x_1, x_2, \dots, x_n\}$ une variable aléatoire discrète alors on a

$$\begin{aligned} \mathbb{E}(X) &= \sum_{i=1}^n x_i \mathbb{P}(X = x_i) \\ &= \sum_{i=1}^n x_i \mathbb{P}_X(\{x_i\}). \end{aligned}$$

On observe que c'est la même formule que l'intégrale de Lebesgue d'une fonction simple.

Définition 34 Si X est une variable aléatoire, on appelle espérance de X l'intégrale de X par rapport à la mesure \mathbb{P} . Plus précisément

$$\mathbb{E}(X) = \int_{\Omega} X(\omega) d\mathbb{P}(\omega).$$

Exemple 35 Soit $A \in \mathcal{F}$ et sa fonction indicatrice 1_A (qui est une variable aléatoire). On a alors

$$\mathbb{E}(X) = \mathbb{E}(1_A) = \int_{\Omega} 1_A(\omega) d\mathbb{P}(\omega) = \mathbb{P}(A).$$

Remarque 36 Pour une variable aléatoire à densité on a

$$\begin{aligned}\mathbb{P}_X(A) &= \int_A f(x) dx \\ d\mathbb{P}_X(A) &= f(x) dx.\end{aligned}$$

Par un changement de variable on a

$$\begin{aligned}\mathbb{E}(X) &= \int_{\Omega} \underbrace{X(\omega)}_{=x} d\mathbb{P}(\omega) \\ &= \int_{\mathbb{R}} x d\mathbb{P}(X^{-1}(x)) \\ &= \int_{\mathbb{R}} x d\mathbb{P}_X(x).\end{aligned}$$

On obtient que

$$\mathbb{E}(X) = \int_{\mathbb{R}} x f(x) dx.$$

Définition 37 Une variable aléatoire X est dite **intégrable** si $|X|$ est d'espérance finie.

Une variable aléatoire X est dite **centrée** si $\mathbb{E}(X) = 0$.

Proposition 38 (Propriétés de l'espérance)

- 1) $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$
- 2) Si $X \geq 0$ et $\mathbb{E}(X) = 0$ alors $\mathbb{P}(X = 0) = 1$

Changement de variable

Soit X une variable aléatoire et $h : \mathbb{R} \rightarrow \mathbb{R}$ une fonction mesurable et $Y = h(X)$.

On voit que

$$\begin{aligned}\mathbb{E}(Y) &= \int_{\Omega} Y(\omega) d\mathbb{P}(\omega) \\ &= \int_{\Omega} h(X(\omega)) d\mathbb{P}(\omega) \\ &= \int_{\mathbb{R}} h(x) d\mathbb{P}(X^{-1}(x)) \\ &= \int_{\mathbb{R}} h(x) d\mathbb{P}_X(x) \\ &= \int_{\mathbb{R}} h(x) f(x) dx.\end{aligned}$$

Proposition 39 (*Inégalité de Markov*) Si X est une variable aléatoire positive

$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}(X)}{t}.$$

Définition 40 Soit $(X_n)_n$ une suite de variables aléatoires. On dit que $X_n \rightarrow X$ presque sûrement (noté p.s.) si $\mathbb{P}(X_n \rightarrow X) = 1$, ce qui signifie $X_n(\omega) \rightarrow X(\omega)$ pour $\forall \omega \in A$ tel que $\mathbb{P}(A) = 1$.

Définition 41 Soit $(X_n)_n$ une suite de variables aléatoires. On dit que $X_n \rightarrow X$ en espérance si $\mathbb{E}(X_n) \rightarrow \mathbb{E}(X)$ pour $n \rightarrow \infty$.

Théorème 42 (de la convergence monotone) Soit $(X_n)_n$ une suite croissante de variables aléatoires telle que $X_n \geq 0$ et $X_n \rightarrow X$ presque sûrement. Alors

$$\mathbb{E}(X_n) \rightarrow \mathbb{E}(X), \quad \text{pour } n \rightarrow \infty.$$

Théorème 43 (de la convergence dominée) Soit $(X_n)_n$ une suite de variables aléatoires telle que $X_n \rightarrow X$ presque sûrement. S'il existe une variable aléatoire Y telle que $\mathbb{E}(Y) < \infty$ (intégrable) et $|X_n| < Y$ p.s., alors $\mathbb{E}(X_n) \rightarrow \mathbb{E}(X)$, pour $n \rightarrow \infty$.

2.4 Moments des variables aléatoires

Définition 44 Une variable aléatoire $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R}$ a un moment d'ordre $p \geq 1$ si et seulement si

$$\mathbb{E}(|X|^p) = \int_{\Omega} |X|^p d\mathbb{P} < \infty.$$

On peut construire l'espace

$$L^p(\Omega, \mathcal{F}, \mathbb{P}) = \left\{ \widehat{X} \text{ les classes d'équivalence de } X : \Omega \rightarrow \mathbb{R}; \mathbb{E}(|X|^p) < \infty \right\}$$

muni de la norme

$$\|X\|_p = (\mathbb{E}(|X|^p))^{1/p}.$$

Remarque 45 On peut montrer que c'est un espace de Banach.

Proposition 46 *On a les propriétés suivantes*

- (Inégalité de Hölder) Soient X et Y deux variables aléatoires qui vérifient $\mathbb{E}(|X|^p) < \infty$ et $\mathbb{E}(|Y|^q) < \infty$ pour $p, q \in \mathbb{R}$ telles que $p, q > 1$ et $\frac{1}{p} + \frac{1}{q} = 1$.

1. Montrer que

$$\mathbb{E}(XY) \leq \mathbb{E}(|X|^p)^{1/p} \mathbb{E}(|Y|^q)^{1/q}.$$

On retrouve l'inégalité de Cauchy-Schwartz pour $p = q = 2$.

- (Inégalité de Minkowski) Soient X et Y deux variables aléatoires $\mathbb{E}(|X|^p) < \infty$ et $\mathbb{E}(|Y|^p) < \infty$, $1 \leq p < \infty$. Montrer que

$$\mathbb{E}(|X + Y|^p)^{1/p} \leq \mathbb{E}(|X|^p)^{1/p} + \mathbb{E}(|Y|^p)^{1/p}.$$

Proposition 47 *Si une variable aléatoire est bornée, elle admet des moments de tous les ordres.*

Définition 48 *Soit X une variable aléatoire. On appelle*

- *moment d'ordre n*

$$\mu_n = \mathbb{E}(X^n), \quad \forall n \in \mathbb{N}$$

- *transformé de Fourier*

$$\Phi_X(t) = \mathbb{E}(e^{itX}), \quad \forall t > 0$$

- *fonction génératrice de moments*

$$M_X(t) = \mathbb{E}(e^{tX}), \quad \forall t > 0.$$

Proposition 49 *Soit X une variable aléatoire positive et $t \geq 0$. Alors*

$$M_X(t) = \sum_{n=0}^{\infty} \frac{t^n \mu_n}{n!}$$

où μ_n est le moment d'ordre n .

Démonstration. On sait que

$$e^{tx} = \sum_{n=0}^{\infty} \frac{t^n x^n}{n!}.$$

On applique l'espérance

$$\begin{aligned} M_X(t) &= \mathbb{E}(e^{tX}) \\ &= \mathbb{E}\left(\sum_{n=0}^{\infty} \frac{t^n X^n}{n!}\right) \\ &= \sum_{n=0}^{\infty} \frac{t^n \mathbb{E}(X^n)}{n!} \\ &= \sum_{n=0}^{\infty} \frac{t^n \mu_n}{n!}. \end{aligned}$$

■

Proposition 50 Soit X une variable aléatoire positive telle que $M_X(t) < \infty$ pour t tel que $|t| < \varepsilon$, où $\varepsilon > 0$. Alors $M_X(t)$ est infiniment dérivable sur $(-\varepsilon, \varepsilon)$ et la dérivé d'ordre r est

$$M_X^{(r)}(t) = \mathbb{E}(e^{tX} X^r).$$

Démonstration. On calcule

$$\begin{aligned} M_X^{(r)}(t) &= \frac{d^r}{dt^r} \left(\sum_{n=0}^{\infty} \frac{t^n \mu_n}{n!} \right) \\ &= \sum_{n=0}^{\infty} \frac{\mu_n}{n!} \frac{d^r}{dt^r} (t^n) \\ &= \sum_{n=r}^{\infty} \frac{\mu_n}{n!} n(n-1) \dots (n-r+1) t^{n-r} \\ &= \sum_{n=r}^{\infty} \frac{\mu_n}{(n-r)!} t^{n-r}. \end{aligned}$$

On note $k = n - r$ et on obtient

$$\begin{aligned} &\sum_{k=0}^{\infty} \frac{\mu_{k+r}}{k!} t^k \\ &= \sum_{k=0}^{\infty} \frac{t^k}{k!} \mathbb{E}(X^{k+r}) \\ &= \mathbb{E} \left(\sum_{k=0}^{\infty} \frac{t^k}{k!} X^{k+r} \right) \\ &= \mathbb{E} \left(\sum_{k=0}^{\infty} \frac{t^k X^k}{k!} X^r \right) \\ &= \mathbb{E}(e^{tX} X^r). \end{aligned}$$

■

Remarque 51 On voit que pour $t = 0$ on a $M_X^{(r)}(0) = \mathbb{E}(X^r)$.

Proposition 52 (Inégalité de Tchebychev) Soit X une variable aléatoire et $p \in [0, \infty)$. Alors

$$\mathbb{P}(|X| \geq \lambda) \leq \frac{1}{\lambda^p} \mathbb{E}(|X|^p).$$

Démonstration. On voit que

$$\begin{aligned}
\mathbb{E}(|X|^p) &= \int_{\Omega} |X|^p d\mathbb{P} \\
&\geq \int_{\{|X| \geq \lambda\}} |X|^p d\mathbb{P} \\
&\geq \lambda^p \int_{\{|X| \geq \lambda\}} d\mathbb{P} \\
&= \lambda^p \mathbb{P}\{|X| \geq \lambda\}.
\end{aligned}$$

■

2.5 Variance

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité et $X : \Omega \rightarrow \mathbb{R}$ une variable aléatoire.

Définition 53 Si $X \in L^2(\Omega, \mathcal{F}, \mathbb{P})$, on définit la variance de X par

$$V(X) = \mathbb{E}[(X - \mathbb{E}(X))^2] = \int_{\Omega} |X - \mathbb{E}(X)|^2 d\mathbb{P}.$$

Si on prend

$$h(x) = |x - \mathbb{E}(X)|^2$$

et par la formule de changement de variables, on a

$$\begin{aligned}
V(X) &= \int_{\Omega} h(X(\omega)) d\mathbb{P}(\omega) \\
&= \int_{\mathbb{R}} h(x) d\mathbb{P}(X^{-1}(x)) \\
&= \int_{\mathbb{R}} |x - \mathbb{E}(X)|^2 d\mathbb{P}_X(x).
\end{aligned}$$

Si X est une variable aléatoire de densité f , alors on a

$$V(X) = \int_{\mathbb{R}} |x - \mathbb{E}(X)|^2 f(x) dx.$$

Proposition 54 On a les propriétés suivantes

$$1) V(X) \geq 0$$

$$2) V(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2$$

$$3) V(aX) = a^2 V(X)$$

$$4) V(b) = 0 \text{ si } b = \text{const.}$$

$$5) V(X + b) = V(X)$$

$$6) V(X) = 0 \text{ ssi } X = \text{const. p.s.}$$

Démonstration.

$$1) \mathbb{E} \left((X - \mathbb{E}(X))^2 \right) \geq 0$$

$$\begin{aligned} 2) V(X) &= \mathbb{E} \left((X - \mathbb{E}(X))^2 \right) = \mathbb{E} \left(X^2 - 2X\mathbb{E}(X) + (\mathbb{E}(X))^2 \right) \\ &= \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \end{aligned}$$

$$3) V(aX) = \mathbb{E} \left((aX - \mathbb{E}(aX))^2 \right) = a^2 \mathbb{E} \left((X - \mathbb{E}(X))^2 \right) = a^2 V(X)$$

$$4) V(b) = \mathbb{E} \left((b - \mathbb{E}(b))^2 \right) = \mathbb{E} \left((b - b)^2 \right) = 0$$

$$5) V(X + b) = \mathbb{E} \left((X + b - \mathbb{E}(X + b))^2 \right) = \mathbb{E} \left((X + b - \mathbb{E}(X) + b)^2 \right) = V(X)$$

$$6) \text{ Si } X = c \text{ (const) alors on a par 4) que } V(X) = 0.$$

Si $V(X) = \mathbb{E} \left((X - \mathbb{E}(X))^2 \right) = 0$ alors la variable $(X - \mathbb{E}(X))^2$ est positive d'espérance nulle et donc nulle presque sûrement.

On obtient $X = \mathbb{E}(X)$.

■

Covariance

Définition 55 Si X et Y sont deux variables aléatoire avec des variances finies, alors on peut définir la covariance de X et Y par

$$\begin{aligned} \text{cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]. \end{aligned}$$

Proposition 56 On a les propriétés suivantes

- 1) $(X, Y) \mapsto \text{cov}(X, Y)$ est une application bilinéaire
- 2) Si X et Y sont des variables aléatoires centrés alors $\text{cov}(X, Y) = \mathbb{E}[XY]$
- 3) Si $X = Y$ alors $\text{cov}(X, X) = V(X)$

Proposition 57 Si X et Y sont deux variables aléatoires avec des variances finies, alors

$$V(X + Y) = V(X) + V(Y) + 2\text{cov}(X, Y).$$

Démonstration. On développe

$$\begin{aligned} V(X + Y) &= \mathbb{E}[(X + Y)^2] - (\mathbb{E}(X + Y))^2 \\ &= \mathbb{E}[X^2 + Y^2 + 2XY] - (\mathbb{E}(X) + \mathbb{E}(Y))^2 \\ &= \mathbb{E}[X^2] + \mathbb{E}[Y^2] + 2\mathbb{E}[XY] \\ &\quad - (\mathbb{E}(X))^2 - (\mathbb{E}(Y))^2 - 2\mathbb{E}(X)\mathbb{E}(Y) \\ &= V(X) + V(Y) + 2\text{cov}(X, Y). \end{aligned}$$

■

Proposition 58 On a

$$|\text{cov}(X, Y)| \leq \sqrt{V(X)V(Y)}.$$

Démonstration. On applique l'inégalité de Holder

$$\begin{aligned} |\text{cov}(X, Y)| &= |\mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]| \\ &\leq \sqrt{\mathbb{E}((X - \mathbb{E}(X))^2) \mathbb{E}((Y - \mathbb{E}(Y))^2)} \\ &\leq \sqrt{V(X)V(Y)}. \end{aligned}$$

■

Corrélation

Définition 59 Soit X, Y deux variables aléatoires avec des variances finies. On définit le coefficient de corrélation est

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{V(X)V(Y)}}.$$

Proposition 60 Si $\rho(X, Y) = \pm 1$ alors il y a un lien linéaire entre X et Y de la forme $Y = aX + b$, pour $a, b \in \mathbb{R}$. En plus on peut montrer que

$$a = \frac{\text{cov}(X, Y)}{V(X)}, \quad b = \mathbb{E}(Y) - a\mathbb{E}(X).$$

Proposition 61 *Si X est une variable aléatoire pour qui $V(X)$ existe, on a*

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq t) \leq \frac{V(X)}{t^2}.$$

Démonstration. On a

$$\begin{aligned} \mathbb{P}(|X - \mathbb{E}(X)| \geq t) &= \mathbb{P}\left(|X - \mathbb{E}(X)|^2 \geq t^2\right) \\ &\leq \frac{\mathbb{E}\left[(X - \mathbb{E}(X))^2\right]}{t^2} \\ &\leq \frac{V(X)}{t^2}. \end{aligned}$$

■

Chapitre 3

Vecteurs aléatoires

3.1 Rappels d'intégration

Définition 62 Soit (X, \mathcal{A}, μ) et (Y, \mathcal{B}, ν) deux espaces mesurés.
On définit l'espace produit

$$X \times Y = \{(x, y) \mid x \in X, y \in Y\}$$

$$\begin{aligned} \mathcal{A} \otimes \mathcal{B} &= \text{tribu produit sur } X \times Y \\ &\text{engendrée par les produits } A \times B \end{aligned}$$

$$\begin{aligned} \mu \otimes \nu &= \text{mesure produit sur } (X \times Y, \mathcal{A} \otimes \mathcal{B}) \\ (\mu \otimes \nu)(A \times B) &= \mu(A) \nu(B). \end{aligned}$$

Exemple 63 $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ où

$$\mathcal{B}(\mathbb{R}^d) = \underbrace{\mathcal{B}(\mathbb{R}) \otimes \dots \otimes \mathcal{B}(\mathbb{R})}_{d \text{ fois}}$$

et

$$\lambda_d = \underbrace{\lambda \otimes \dots \otimes \lambda}_{d \text{ fois}}$$

où

$$\begin{aligned} \lambda &: \mathcal{B}(\mathbb{R}) \rightarrow \mathbb{R}_+ \\ \lambda([a, b]) &= b - a. \end{aligned}$$

On obtient

$$\lambda_d([a_1, b_1] \times \dots \times [a_d, b_d]) = (b_1 - a_1)(b_2 - a_2) \dots (b_d - a_d).$$

Théorème 64 (Fubini-Tonelli) Soit $f : (X \times Y, \mathcal{A} \otimes \mathcal{B}) \rightarrow \mathbb{R}_+$ et μ et ν sont deux mesures sur (X, \mathcal{A}) et (Y, \mathcal{B}) . Alors

1)

$$x \mapsto \int_Y f(x, y) d\nu(y) \text{ et } y \mapsto \int_X f(x, y) d\mu(x) \text{ sont mesurables.}$$

2)

$$\begin{aligned} \int_{X \times Y} f(x, y) d(\mu \otimes \nu)(x, y) &= \int_X \left(\int_Y f(x, y) d\nu(y) \right) d\mu(x) \\ &= \int_Y \left(\int_X f(x, y) d\mu(x) \right) d\nu(y). \end{aligned}$$

Changement de variable

Soit (X, \mathcal{A}, μ) et (Y, \mathcal{B}, ν) deux espaces mesurables et $\varphi : (X, \mathcal{A}) \rightarrow (Y, \mathcal{B})$ une fonction telle que $\nu = \mu\varphi^{-1}$.

Théorème 65 (Transfert) Si $h : (Y, \mathcal{B}) \rightarrow \mathbb{R}$ est une fonction mesurable alors

$$\int_X h(\varphi(x)) d\mu(x) = \int_Y h(y) d\nu(y).$$

Intégrale de Riemann

1) Sur \mathbb{R}

$$\int_I f(x) dx = \int_{\varphi(I)} f(\varphi^{-1}(y)) |(\varphi^{-1})'(y)| dy.$$

2) Sur \mathbb{R}^d

$$\int_V f(x) d\lambda(x) = \int_{\varphi(V)} f(\varphi^{-1}(y)) |J_{\varphi^{-1}}(y)| d\lambda(y).$$

Coordonnées polaires et sphériques

1) Soit $(x, y) \in \mathbb{R}^2$ et $(r, \theta) \in [0, \infty) \times [0, 2\pi)$ telles que

$$\begin{cases} x = r \cos \theta \\ y = r \sin \theta \end{cases}.$$

Alors

$$\varphi^{-1}(r, \theta) = (r \cos \theta, r \sin \theta) = (x(r, \theta), y(r, \theta))$$

et donc

$$J_{\varphi^{-1}}(r, \theta) = \begin{vmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{vmatrix} = r.$$

Donc

$$\iint_{\mathbb{R}^2} f(x, y) dx dy = \int_0^\infty \int_0^{2\pi} f(r \cos \theta, r \sin \theta) r dr d\theta.$$

2) Soit $(x, y, z) \in \mathbb{R}^3$ et $(r, \varphi, \theta) \in [0, \infty) \times [0, 2\pi) \times [-\frac{\pi}{2}, \frac{\pi}{2}]$ telles que

$$\begin{cases} x = r \cos \theta \cos \varphi \\ y = r \cos \theta \sin \varphi \\ z = r \sin \theta \end{cases}.$$

Alors

$$\begin{aligned} \varphi^{-1}(r, \theta, \varphi) &= (r \cos \theta \cos \varphi, r \cos \theta \sin \varphi, r \sin \theta) \\ &= (x(r, \theta, \varphi), y(r, \theta, \varphi), z(r, \theta, \varphi)) \end{aligned}$$

et donc

$$J_{\varphi^{-1}}(r, \theta, \varphi) = \begin{vmatrix} \cos \theta \cos \varphi & -r \sin \theta \cos \varphi & -r \cos \theta \sin \varphi \\ \cos \theta \sin \varphi & -r \sin \theta \sin \varphi & -r \sin \theta \cos \varphi \\ \sin \theta & r \cos \theta & 0 \end{vmatrix} = r^2 \cos \theta.$$

Donc

$$\begin{aligned} & \iiint_{\mathbb{R}^3} f(x, y, z) dx dy dz \\ &= \int_0^\infty \int_0^{2\pi} \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} f(r \cos \theta \cos \varphi, r \cos \theta \sin \varphi, r \sin \theta) r^2 \cos \theta d\theta d\varphi dr. \end{aligned}$$

3.2 Vecteurs aléatoires

Définition 66 On appelle *vecteur aléatoire* une application $X : \Omega \rightarrow \mathbb{R}^d$ qui est mesurable. Si $X = (X_1, X_2, \dots, X_d)$, on appelle les applications X_i *marginales* de X .

Définition 67 La loi d'un vecteur aléatoire est une mesure de probabilité sur \mathbb{R}^d définie par

$$\begin{aligned} & \mathbb{P}_X(A_1 \times A_2 \times \dots \times A_d) \\ &= \mathbb{P}(X_1 \in A_1, X_2 \in A_2, \dots, X_d \in A_d), \quad \forall A_i \in \mathcal{B}(\mathbb{R}). \end{aligned}$$

Définition 68 Un vecteur aléatoire X est **discret** si $X(\Omega)$ est discret dans \mathbb{R}^d .

Un vecteur aléatoire X est **de loi à densité** si la loi est absolument continue par rapport à la mesure de Lebesgue dans \mathbb{R}^d . ($\mathbb{P}_X \ll \lambda_{\mathbb{R}^d}$). Alors

$$\mathbb{P}_X(A) = \int_A f(x_1, x_2, \dots, x_d) dx_1 dx_2 \dots dx_d, \quad \forall A \in \mathcal{B}(\mathbb{R}^d)$$

où f est une densité i.e., $f \geq 0$ et $\int_{\mathbb{R}^d} f(x_1, x_2, \dots, x_d) dx_1 dx_2 \dots dx_d = 1$.

Proposition 69 Si (X, Y) est un vecteur aléatoire de loi $\mathbb{P}_{(X,Y)} = \mu$ alors on peut obtenir les lois marginales \mathbb{P}_X et \mathbb{P}_Y de X et Y par

$$\mathbb{P}_X(A) = \mu(A \times \mathbb{R}) \text{ et } \mathbb{P}_Y(B) = \mu(\mathbb{R} \times B).$$

Démonstration. On voit facilement que

$$\begin{aligned} \mathbb{P}_X(A) &= \mathbb{P}(\{X \in A\}) \\ &= \mathbb{P}(\{(x, y) \in A \times \mathbb{R}\}) \\ &= \mu(A \times \mathbb{R}). \end{aligned}$$

■

Exemple 70 (Cas discret)

$$(X, Y)(\Omega) = \{(x_1, y_1), \dots, (x_i, y_i), \dots\}$$

$$\begin{aligned} X(\Omega) &= \{x_1, x_2, \dots, x_i, \dots\} \\ Y(\Omega) &= \{y_1, y_2, \dots, y_i, \dots\} \end{aligned}$$

$$\mathbb{P}_X(x_i) = \mathbb{P}(X = x_i) = \sum_{y_j \in Y(\Omega)} \mathbb{P}(X = x_i; Y = y_j).$$

Exemple 71 (Cas à densité)

Soit (X, Y) un couple de variables aléatoires de loi $\mathbb{P}_{(X,Y)}$ de densité f . Alors les lois marginales \mathbb{P}_X et \mathbb{P}_Y sont des lois de densités donnés par

$$\begin{aligned} f_X(x) &= \int_{\mathbb{R}} f(x, y) dy \\ f_Y(y) &= \int_{\mathbb{R}} f(x, y) dx. \end{aligned}$$

Démonstration. On voit que

$$\begin{aligned} \mathbb{P}_X(A) &= \mathbb{P}(X \in A; Y \in \mathbb{R}) \\ &= \mathbb{P}((X, Y) \in A \times \mathbb{R}) \\ &= \mathbb{P}_{(X,Y)}(A \times \mathbb{R}) \\ &= \int_{A \times \mathbb{R}} f(x, y) dx dy \\ &= \int_A \left(\int_{\mathbb{R}} f(x, y) dy \right) dx \\ &= \int_A f_X(x) dx, \end{aligned}$$

donc f_X est la densité de loi \mathbb{P}_X . ■

Généralisation

Soit $X = (X_1, X_2, \dots, X_d)$ de densité f . Alors la loi de la variable marginale X_i est de densité

$$f_{X_i}(x_i) = \int_{\mathbb{R}^{d-1}} f(x_1, x_2, \dots, x_d) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_d.$$

En effet

$$\begin{aligned} \mathbb{P}(X_i \in A) &= \mathbb{P}(X_1 \in \mathbb{R}, \dots, X_i \in A, \dots, X_d \in \mathbb{R}) \\ &= \int_{A \times \mathbb{R}^{d-1}} f(x_1, x_2, \dots, x_i, \dots, x_d) dx_1 \dots dx_i \dots dx_d \\ &= \int_A f_{X_i}(x_i) dx_i. \end{aligned}$$

3.3 Fonction d'un vecteur aléatoire

Soit $Z = (X, Y)$ un vecteur aléatoire et $h : \mathbb{R}^2 \rightarrow \mathbb{R}$.

Esperance

$$\begin{aligned} \mathbb{E}(h(X, Y)) &= \int_{\Omega} h(X(\omega), Y(\omega)) d\mathbb{P}(\omega) \\ &= \iint_{\mathbb{R}^2} h(x, y) d\mathbb{P}_{(X, Y)}(x, y). \end{aligned}$$

Loi

$$\begin{aligned} \mathbb{E}(g(h(X, Y))) &= \iint_{\mathbb{R}^2} g(h(x, y)) d\mathbb{P}_{(X, Y)}(x, y) \\ &= \iint_{\mathbb{R}^2} g(h(x, y)) f_{(X, Y)}(x, y) dx dy. \end{aligned}$$

On fait un changement de variable $u = h(x, y)$ on obtient

$$\mathbb{E}(g(h(X, Y))) = \iint_{\mathbb{R}^2} g(u) f_{(X, Y)}(x(u, v), y(u, v)) |J| du dv.$$

On intègre par rapport à v .

Chapitre 4

Indépendance

Définition 72 Deux événements A et B d'un espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$ sont indépendantes si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B).$$

Remarque 73 Il ne faut pas confondre avec incompatibilité, i.e. $A \cap B = \emptyset$.

Définition 74 Une famille d'événements A_1, A_2, \dots, A_n sont mutuellement indépendantes si pour toute sous-famille $A_{i_1}, A_{i_2}, \dots, A_{i_k}$ on a

$$\mathbb{P}(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1}) \dots \mathbb{P}(A_{i_k}).$$

Définition 75 Deux tribus (σ -algèbre) \mathcal{F} et \mathcal{G} sur un même espace de probabilité Ω sont indépendantes si pour tout $A \in \mathcal{F}$ et $B \in \mathcal{G}$ on a

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B).$$

Indépendance de variables aleatoires

Définition 76 Deux variables aléatoires X et Y sont indépendantes si les tribus engendrées par X et Y sont indépendantes.

Proposition 77 Deux variables aléatoires X et Y sont indépendantes si pour tout $A, B \in \mathcal{B}(\mathbb{R})$ les événements $\{X \in A\}$ et $\{Y \in B\}$ sont indépendantes, i.e.

$$\mathbb{P}(X \in A; Y \in B) = \mathbb{P}(X \in A) \mathbb{P}(Y \in B)$$

ou

$$\mathbb{P}(X^{-1}(A) \cap Y^{-1}(B)) = \mathbb{P}(X^{-1}(A)) \mathbb{P}(Y^{-1}(B)).$$

Définition 78 Une famille de variables aléatoires X_1, X_2, \dots, X_n sont dites mutuellement indépendantes si pour toute famille d'évènements $A_{i_1}, A_{i_2}, \dots, A_{i_k} \in \mathcal{B}(\mathbb{R})$ les évènements $\{X_{i_1} \in A_{i_1}\}, \dots, \{X_{i_k} \in A_{i_k}\}$ sont indépendantes.

Définition 79 Une suite de variables aléatoires $(X_i)_{i \in \mathbb{N}}$ est dite indépendante si toute famille finie d'éléments de $(X_i)_{i \in \mathbb{N}}$ a la propriété précédente.

Indépendance de vecteurs aleatoires

Proposition 80 Un vecteur aléatoire $X = (X_1, X_2, \dots, X_n)$ est à composantes indépendantes si et seulement si sa loi \mathbb{P}_X est une loi produit de ses lois marginales

$$\mathbb{P}_X = \mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2} \otimes \dots \otimes \mathbb{P}_{X_n}.$$

Démonstration. Soit

$$B = B_1 \times B_2 \times \dots \times B_n \in \mathcal{B}(\mathbb{R}^n).$$

Alors

$$\begin{aligned} \mathbb{P}_X(B) &= \mathbb{P}((X_1, X_2, \dots, X_n) \in B_1 \times B_2 \times \dots \times B_n) \\ &= \mathbb{P}(X_1 \in B_1, X_2 \in B_2, \dots, X_n \in B_n) \\ &\stackrel{\text{indép}}{=} \mathbb{P}(X_1 \in B_1) \mathbb{P}(X_2 \in B_2) \dots \mathbb{P}(X_n \in B_n) \\ &= \mathbb{P}_{X_1}(B_1) \mathbb{P}_{X_2}(B_2) \dots \mathbb{P}_{X_n}(B_n) \\ &= \mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2} \otimes \dots \otimes \mathbb{P}_{X_n}(B_1 \times B_2 \times \dots \times B_n) \\ &= \mathbb{P}_{X_1} \otimes \mathbb{P}_{X_2} \otimes \dots \otimes \mathbb{P}_{X_n}(B). \end{aligned}$$

■

Corollaire 81 Les variables aléatoires X_1, X_2, \dots, X_n sont indépendantes si et seulement si

$$\mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n) = \mathbb{P}(X_1 \leq x_1) \mathbb{P}(X_2 \leq x_2) \dots \mathbb{P}(X_n \leq x_n).$$

Applications

1) Cas discret

Les variables aléatoires X et Y sont indépendantes si et seulement si $\forall x \in X(\Omega)$ et $\forall y \in Y(\Omega)$ on a

$$\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x) \mathbb{P}(Y = y).$$

2) Cas à densité

Les variables aléatoires X et Y de densités f et g sont indépendantes si et seulement si (X, Y) a comme densité

$$\begin{aligned} f \otimes g &: \mathbb{R}^2 \rightarrow \mathbb{R} \\ (f \otimes g)(x, y) &= f(x)g(y). \end{aligned}$$

Proposition 82 Soient $\{X_i\}_{1 \leq i \leq n}$ des variables aléatoires indépendantes et $h_i : \mathbb{R} \rightarrow \mathbb{R}$, $1 \leq i \leq n$, des fonctions mesurables telles que $h_i(X_i)$ sont intégrables.

Alors le produit $\prod_{i=1}^n h_i(X_i)$ est intégrable et

$$\mathbb{E} \left(\prod_{i=1}^n h_i(X_i) \right) = \prod_{i=1}^n \mathbb{E}(h_i(X_i)).$$

Démonstration. On voit que

$$\begin{aligned} \mathbb{E} \left(\prod_{i=1}^n h_i(X_i) \right) &= \int_{\Omega} \prod_{i=1}^n h_i(X_i) d\mathbb{P} \\ &= \int_{\mathbb{R}^n} \prod_{i=1}^n h_i(x_i) d\mathbb{P}_{(X_1, X_2, \dots, X_n)}(x_1, x_2, \dots, x_n) \\ &= \int_{\mathbb{R}^n} \prod_{i=1}^n h_i(x_i) d\mathbb{P}_{X_1}(x_1) d\mathbb{P}_{X_2}(x_2) \dots d\mathbb{P}_{X_n}(x_n) \\ &= \int_{\mathbb{R}} h_1(x_1) d\mathbb{P}_{X_1}(x_1) \int_{\mathbb{R}} h_2(x_2) d\mathbb{P}_{X_2}(x_2) \dots \int_{\mathbb{R}} h_n(x_n) d\mathbb{P}_{X_n}(x_n) \\ &= \mathbb{E}(h_1(X_1)) \mathbb{E}(h_2(X_2)) \dots \mathbb{E}(h_n(X_n)). \end{aligned}$$

■

Corollaire 83 Soient X_1, X_2, \dots, X_n des variables aléatoires indépendantes et intégrables. Alors

$$\mathbb{E}(X_1 X_2 \dots X_n) = \mathbb{E}(X_1) \mathbb{E}(X_2) \dots \mathbb{E}(X_n).$$

Covariance et indépendance

Proposition 84 Soient X et Y deux v.a. indépendantes avec variances finies. Alors $\text{cov}(X, Y) = 0$.

Démonstration.

$$\text{cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

■

Corollaire 85 *Si X et Y sont deux variables aléatoires indépendantes avec variances finies alors on a*

$$V(X + Y) = V(X) + V(Y).$$

Proposition 86 *Si X et Y sont deux variables aléatoires indépendantes alors pour toute fonction f et g on a que $f(X)$ et $g(Y)$ sont aussi indépendantes.*

Chapitre 5

Espérance conditionnelle

On rappelle que la probabilité conditionnelle est définie par

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{E}(1_A 1_B)}{\mathbb{P}(B)}$$

car $\mathbb{P}(A) = \mathbb{E}(1_A)$ et $1_A 1_B = 1_{A \cap B}$.

Pour une variable aléatoire $X : \Omega \rightarrow \mathbb{R}$ on définit

$$\mathbb{E}(X|B) = \frac{\mathbb{E}(X \cdot 1_B)}{\mathbb{P}(B)} = \frac{1}{\mathbb{P}(B)} \int_{\Omega} X 1_B d\mathbb{P} = \int_{\Omega} X \frac{1_B}{\mathbb{P}(B)} d\mathbb{P}.$$

Comme $\frac{1_B}{\mathbb{P}(B)}$ est une densité on peut noter $\frac{1_B}{\mathbb{P}(B)} d\mathbb{P} = d\mathbb{P}_B$ où

$$\mathbb{P}_B(A) = \int_A 1_B \frac{1}{\mathbb{P}(B)} d\mathbb{P} = \int_{\Omega} 1_{A \cap B} \frac{1}{\mathbb{P}(B)} d\mathbb{P} = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Soit X une variable aléatoire intégrable sur un espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$ et \mathcal{B} une σ -algèbre (tribu) telle que $\mathcal{B} \subset \mathcal{F}$.

Définition 87 On définit l'espérance conditionnelle de X sachant \mathcal{B} une variable aléatoire intégrable Z qui a les propriétés suivantes

- i) Z est mesurable par rapport à \mathcal{B}
- ii) pour tout $A \in \mathcal{B}$ on a

$$\mathbb{E}(X \cdot 1_A) = \mathbb{E}(Z \cdot 1_A)$$

ou

ii)' pour tout variable aléatoire Y qui est borné et \mathcal{B} -mesurable on a

$$\mathbb{E}(XY) = \mathbb{E}(ZY).$$

On note $Z = \mathbb{E}(X | \mathcal{B})$.

Remarque 88 *La variable aléatoire Z est unique.*

Démonstration. Soit Z' une variable aléatoire qui vérifie les deux conditions.
On a

$$\mathbb{E}((Z - Z') 1_A) = 0 \text{ et } \mathbb{E}((Z - Z') 1_{\bar{A}}) = 0.$$

Soit

$$A = \{\omega \in \Omega \mid Z'(\omega) < Z(\omega)\}$$

$$\begin{aligned} \mathbb{E}((Z - Z') 1_A) &= 0 \\ (Z - Z') 1_A &\geq 0 \end{aligned}$$

on a $Z = Z'$ p.s. A .

De la même façon, pour

$$\bar{A} = \{\omega \in \Omega \mid Z'(\omega) \geq Z(\omega)\}$$

$$\begin{aligned} \mathbb{E}((Z' - Z) 1_{\bar{A}}) &= 0 \\ (Z' - Z) 1_{\bar{A}} &\geq 0 \end{aligned}$$

on a $Z = Z'$ p.s. \bar{A} . ■

Proposition 89 (Propriétés spécifiques)

1) On a

$$\mathbb{E}(\mathbb{E}(X | \mathcal{B})) = \mathbb{E}(X)$$

2) Si X est indépendant de \mathcal{B} , alors

$$\mathbb{E}(X | \mathcal{B}) = \mathbb{E}(X)$$

3) Si X est \mathcal{B} - mesurable, alors

$$\mathbb{E}(X | \mathcal{B}) = X$$

4) Si Y est une variable aléatoire bornée et \mathcal{B} - mesurable, alors

$$\mathbb{E}(YX | \mathcal{B}) = Y\mathbb{E}(X | \mathcal{B})$$

5) Soit $\mathcal{G} \subset \mathcal{B}$ deux σ -algèbre. Alors

$$\mathbb{E}(\mathbb{E}(X | \mathcal{B}) | \mathcal{G}) = \mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{B}) = \mathbb{E}(X | \mathcal{G})$$

Démonstration.

1) On choisi $A = \Omega$ et on applique *ii*)

$$\left. \begin{array}{l} \mathbb{E}(X1_\Omega) = \mathbb{E}(X) \\ \mathbb{E}(Z1_\Omega) = \mathbb{E}(Z) \end{array} \right\} \Rightarrow \mathbb{E}(X) = \mathbb{E}(Z)$$

donc $\mathbb{E}(\mathbb{E}(X|\mathcal{B})) = \mathbb{E}(X)$.

2) On a

$$\begin{aligned} \mathbb{E}(X1_A) &= \mathbb{E}(X)\mathbb{E}(1_A) \\ &= \mathbb{E}(\mathbb{E}(X)1_A) \\ &= \mathbb{E}(\mathbb{E}(X|\mathcal{B})1_A), \quad \forall A \in \mathcal{B}. \end{aligned}$$

Donc

$$\mathbb{E}(X) = \mathbb{E}(X|\mathcal{B}) \text{ p.s.}$$

3) Comme X est \mathcal{B} -mesurable, alors c'est évident que

$$\mathbb{E}(X|\mathcal{B}) = X$$

4) On a

$$\left. \begin{array}{l} \mathbb{E}(Y\mathbb{E}(X|\mathcal{B})1_A) = \mathbb{E}(XY1_A) \\ \mathbb{E}(\mathbb{E}(XY|\mathcal{B})1_A) = \mathbb{E}(XY1_A) \end{array} \right\} \Rightarrow \mathbb{E}(YX|\mathcal{B}) = Y\mathbb{E}(X|\mathcal{B}).$$

5) C'est évident en utilisant 3).

■

Proposition 90 (Propriétés similaires aux celles de l'espérance)

1) *Linéarité*

$$\mathbb{E}((aX + b)|\mathcal{B}) = a\mathbb{E}(X|\mathcal{B}) + b.$$

$$\mathbb{E}((X_1 + X_2)|\mathcal{B}) = \mathbb{E}(X_1|\mathcal{B}) + \mathbb{E}(X_2|\mathcal{B}).$$

2) *Monotonie*

$$X_1 \leq X_2 \text{ p.s. alors } \mathbb{E}(X_1|\mathcal{B}) \leq \mathbb{E}(X_2|\mathcal{B}).$$

3) Si X et X_n sont des variables aléatoire réelles dans $L^1(\Omega, \mathcal{A}, \mathbb{P})$ alors $X_n \nearrow X$ implique $\mathbb{E}(X_n|\mathcal{B}) \nearrow \mathbb{E}(X|\mathcal{B})$.

4) Soit f une fonction continue et convexe et X une variable aléatoire réelle telle que X et $f(X)$ sont intégrables, alors

$$f(\mathbb{E}(X|\mathcal{B})) \leq \mathbb{E}(f(X)|\mathcal{B}).$$

5) Si on a $X_n \rightarrow X$ p.s. et $|X_n| \leq Z \in L^1(\Omega, \mathcal{A}, \mathbb{P})$. Alors

$$\lim_{n \rightarrow \infty} \mathbb{E}(X_n|\mathcal{B}) = \mathbb{E}(X|\mathcal{B}).$$

Chapitre 6

Somme de deux variables aléatoires

6.1 Convolution de mesures et de fonctions

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité qui a une structure d'espace vectoriel pour Ω .

Définition 91 Pour deux mesures de probabilité μ et ν sur Ω on définit la convolution

$$(\mu * \nu)(A) = \int_{\Omega} \mu(A - x) d\nu(x)$$

où $A - x = \{a - x \mid a \in A\}$.

On sait que :

- $\mu * \nu = \nu * \mu$
- $\mu * \nu$ est une mesure de probabilité
- $\mu * \delta_0 = \delta_0 * \mu = \mu$ où $\delta_0(A) = \begin{cases} 1, & \text{si } 0 \in A \\ 0, & \text{si } 0 \notin A \end{cases}$ (la mesure de Dirac).

Définition 92 Pour deux fonctions réelles f et g , la convolution est une fonction donnée par

$$(f * g)(x) = \int_{\mathbb{R}} f(x - y) g(y) dy.$$

Proposition 93 Soient μ et ν des mesures de densité f et g par rapport à une mesure λ , i.e. $d\mu = f d\lambda$ et $d\nu = g d\lambda$. Alors on a

$$(\mu * \nu)(A) = \int_A (f * g) d\lambda.$$

Démonstration. On voit que

$$\begin{aligned} (\mu * \nu)(A) &= \int_{\Omega} \mu(A - x) d\nu(x) \\ &= \int_{\Omega} \int_{\Omega} 1_{(A-x)}(y) d\mu(y) d\nu(x) \\ &= \int_{\Omega} \int_{\Omega} 1_A(x+y) d\mu(y) d\nu(x) \\ &= \int_{\{x+y \in A\}} f(x) g(y) dx dy \\ &\stackrel{t=x \text{ et } s=x+y}{=} \int_A \left(\int_{\mathbb{R}} f(t) g(s-t) dt \right) ds \\ &= \int_A (f * g)(s) ds. \end{aligned}$$

■

6.2 Loi d'une somme de variables aléatoires indépendantes à densité

Proposition 94 Soient X et Y deux variables aléatoires indépendantes et de loi \mathbb{P}_X et \mathbb{P}_Y . Alors la loi de $X + Y$ est $\mathbb{P}_X * \mathbb{P}_Y$.

Proposition 95 Soient X et Y deux variables aléatoires indépendantes et de densités f et g . La loi de $X + Y$ est donné par

$$\mathbb{P}_{X+Y}(A) = \mathbb{P}(X + Y \in A) = \int_A (f * g)(x) dx$$

pour tout $A \in \mathcal{B}(\mathbb{R})$. En fait, $X + Y$ a la densité $f * g$.

Démonstration. On sait par la proposition précédente que

$$\mathbb{P}_{X+Y} = \mathbb{P}_X * \mathbb{P}_Y$$

et par la Proposition 93

$$(\mathbb{P}_X * \mathbb{P}_Y)(A) = \int_A (f * g)(x) dx.$$

On obtient que

$$\mathbb{P}_{X+Y}(A) = \int_A (f * g)(x) dx.$$

■

Chapitre 7

Convergences de variables aléatoires

7.1 Convergence presque sûre

Définition 96 Une suite de variables aléatoires $(X_n)_n$ converge presque sûrement vers X si on a

$$\mathbb{P} \left(\left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \right\} \right) = 1.$$

On note

$$X_n \rightarrow X \quad \text{p.s.}$$

7.2 Convergence en norme L^p

On rappelle que pour tout $p > 1$ on définit les espaces

$$L^p(\Omega) = \left\{ \hat{X} : \Omega \rightarrow \mathbb{R} \mid \|X\|_p = (\mathbb{E}|X|^p)^{1/p} < \infty \right\}.$$

On sait que c'est une espace de Banach pour la norme $\|\cdot\|_p$. On remarque que pour $p = 2$ on a un espace de Hilbert avec

$$\langle X, Y \rangle = \mathbb{E}(XY).$$

Définition 97 Une suite de variables aléatoires $(X_n)_n$ converge en norme L^p vers X si on a

$$\lim_{n \rightarrow \infty} \|X_n - X\|_p = 0$$

ou

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^p) = 0.$$

On note

$$X_n \xrightarrow{L^p} X.$$

7.3 Convergence en loi

Une suite de variables aléatoires $(X_n)_n$ converge en loi vers une variable aléatoire X si les fonctions de répartition F_n des variables X_n convergent vers la fonction de répartition F de la variable X en tout point. Donc

$$F_n(x) \longrightarrow F(x), \quad \forall x \in \mathbb{R}.$$

On note

$$X_n \xrightarrow{\mathcal{L}} X.$$

Formes équivalentes :

- On dit que la suite de variables aléatoires $(X_n)_n$ converge en loi vers une variable aléatoire X si

$$\lim_{n \rightarrow \infty} \mathbb{E}(f(X_n)) = \mathbb{E}(f(X)),$$

pour toute fonction continue et bornée f .

- On dit que la suite de variables aléatoires $(X_n)_n$ converge en loi vers une variable aléatoire X si

$$\lim_{n \rightarrow \infty} \int_{\mathbb{R}} f(x) d\mathbb{P}_{X_n}(x) = \int_{\mathbb{R}} f(x) d\mathbb{P}_X(x),$$

pour toute fonction continue et bornée f .

7.4 Convergence en probabilité

Une suite de variables aléatoires $(X_n)_n$ converge en probabilité vers X si pour tout $\varepsilon > 0$ on a

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X - X_n| \geq \varepsilon) = 0.$$

On note

$$X_n \xrightarrow{\mathbb{P}} X.$$

7.5 Relations entre les types de convergence

Proposition 98 *La convergence en probabilité implique la convergence en loi. La réciproque est en général fausse.*

Proposition 99 *Si une suite de variables aléatoires $(X_n)_n$ converge en loi vers la constante C , alors $(X_n)_n$ converge en probabilité vers C .*

Démonstration. On sait que

$$\mathbb{P}(|X_n - C| \geq \varepsilon) = \mathbb{E}(1_{\{|X_n - C| \geq \varepsilon\}}).$$

De l'autre côté on observe que

$$|X_n - C| \geq \varepsilon \Leftrightarrow X_n \in (-\infty, C - \varepsilon) \cup (C + \varepsilon, +\infty)$$

et donc

$$1_{\{|X_n - C| \geq \varepsilon\}} = 1_{\{(-\infty, C - \varepsilon) \cup (C + \varepsilon, +\infty)\}}(X_n) \stackrel{Not}{=} h(X_n).$$

On définit aussi une fonction

$$g(x) = \begin{cases} 1, & x \leq C - \varepsilon \text{ ou } x \geq C + \varepsilon \\ \text{afine}, & x \in (C - \varepsilon, C + \varepsilon) \setminus C \\ 0, & x = C \end{cases}$$

On remarque que g est continue, bornée et que $h \leq g$.

On revient à la première relation

$$\begin{aligned} \mathbb{P}(|X_n - C| \geq \varepsilon) &= \mathbb{E}(1_{\{|X_n - C| \geq \varepsilon\}}) \\ &= \mathbb{E}(1_{\{(-\infty, C - \varepsilon) \cup (C + \varepsilon, +\infty)\}}(X_n)) \\ &= \mathbb{E}(h(X_n)) \leq \mathbb{E}(g(X_n)) \\ &\leq \int_{\Omega} g(X_n) d\mathbb{P} \rightarrow \int_{\Omega} g(C) d\mathbb{P} = g(C) = 0. \end{aligned}$$

Donc

$$\mathbb{P}(|X_n - C| \geq \varepsilon) \xrightarrow{n \rightarrow \infty} 0$$

ce qui est la convergence en probabilité. ■

Proposition 100 Si X_n et X sont des variables aléatoires dans $L^p(\Omega)$, alors la convergence $X_n \xrightarrow{L^p} X$ entraîne la convergence en probabilité $X_n \xrightarrow{\mathbb{P}} X$.

Démonstration. On applique l'inégalité de Tchevychev


$$\begin{aligned} \mathbb{P}(|X_n - X| \geq \varepsilon) &= \mathbb{P}(|X_n - X|^p \geq \varepsilon^p) \\ &\leq \frac{\mathbb{E}(|X_n - X|^p)}{\varepsilon^p} \\ &= \frac{\|X_n - X\|_p^p}{\varepsilon^p} \rightarrow 0 \text{ pour } n \rightarrow \infty. \end{aligned}$$

■

Proposition 101 Si une suite de variables aléatoires $(X_n)_n$ converge en presque sûrement vers une variable aléatoire X alors elle converge aussi en probabilité.

Proposition 102 Si la suite $(X_n)_n$ converge en probabilité vers X , alors elle admet une sous-suite $(X_{n_k})_k$ qui converge presque sûrement vers X .

Schéma



Chapitre 8

Lois des grandes nombres

La loi des grands nombres représente la convergence de la moyenne arithmétique vers la moyenne probabiliste (espérance).

8.1 Version faible de la LGN

Théorème 103 Soit $(X_n)_n$ une suite de variables aléatoires indépendantes et de même loi (i.i.d.) avec un moment d'ordre deux. Alors

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} \mathbb{E}(X_1), \quad \text{pour } n \rightarrow \infty.$$

Démonstration. On observe que la variable aléatoire limite est la constante $\mathbb{E}(X_1)$ qui est égale à $\mathbb{E}(X_i)$ pour tout i car les variables aléatoires X_i ont la même loi, donc la même espérance.

On doit montrer que pour tout $\varepsilon > 0$ on a

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - \mathbb{E}(X_1) \right| \geq \varepsilon \right) = 0. \quad (8.1)$$

Posons

$$M_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Par la linéarité de l'espérance on a

$$\mathbb{E}(M_n) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \mathbb{E}(X_1).$$

D'autre part, par l'indépendance des variables aléatoires X_i , on a

$$\begin{aligned} V(M_n) &= V\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} V\left(\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n V(X_i) = \frac{V(X_1)}{n}. \end{aligned}$$

On rappelle l'inégalité de Tchebychev

$$\begin{aligned} \mathbb{P}(|X| > \varepsilon) &\leq \frac{\mathbb{E}(|X|^p)}{\varepsilon^p} \\ \mathbb{P}(|X - \mathbb{E}(X)| > \varepsilon) &\leq \frac{\mathbb{E}\left((X - \mathbb{E}(X))^2\right)}{\varepsilon^2} = \frac{V(X)}{\varepsilon^2}. \end{aligned}$$

On revient à l'équation (8.1) et en remplaçant, on obtient que

$$\begin{aligned} &\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mathbb{E}(X_1)\right| \geq \varepsilon\right) \\ &= \lim_{n \rightarrow \infty} \mathbb{P}(|M_n - \mathbb{E}(M_n)| \geq \varepsilon) \\ &\leq \lim_{n \rightarrow \infty} \frac{\mathbb{E}\left((M_n - \mathbb{E}(M_n))^2\right)}{\varepsilon^2} \\ &= \lim_{n \rightarrow \infty} \frac{V(M_n)}{\varepsilon^2} \\ &= \lim_{n \rightarrow \infty} \frac{V(X_1)}{\varepsilon^2 n} = 0. \end{aligned}$$

■

Exemple 104 On souhaite estimer le paramètre p inconnu d'une loi de Bernoulli en observant un grand nombre de fois le phénomène aléatoire de loi $\mathcal{B}(p)$, c'est à dire en observant les réalisations d'une suite de variables aléatoires indépendantes X_i , $1 \leq i \leq n$ de loi $\mathcal{B}(p)$.

Notons

$$X_i = \begin{cases} 0, & \text{avec probabilité } 1-p \\ 1, & \text{avec probabilité } p \end{cases}.$$

et

$$M_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{} p.$$

On a

$$\mathbb{P}(|M_n - p| > \varepsilon) \leq \frac{V(X_1)}{n\varepsilon^2} = \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}$$

(car on majore $p(1-p)$ par $\frac{1}{4}$).

On obtient

$$|M_n - p| > \varepsilon \Leftrightarrow |p - M_n| > \varepsilon$$

$$\begin{aligned}\mathbb{P}(|p - M_n| > \varepsilon) &= 1 - \mathbb{P}(|p - M_n| < \varepsilon) \\ &= 1 - \mathbb{P}(-\varepsilon < p - M_n < \varepsilon).\end{aligned}$$

Finalement

$$\begin{aligned}\mathbb{P}(M_n - \varepsilon < p < M_n + \varepsilon) &= 1 - \mathbb{P}(|p - M_n| > \varepsilon) \\ &= 1 - \mathbb{P}(|M_n - p| > \varepsilon) \\ &\geq 1 - \frac{1}{4n\varepsilon^2}.\end{aligned}$$

et donc

$$\mathbb{P}(M_n - \varepsilon < p < M_n + \varepsilon) \geq \underbrace{1 - \frac{1}{4n\varepsilon^2}}_{\stackrel{\text{Not}}{=} 1-\alpha}.$$

On note par $1 - \alpha$ la probabilité d'erreur et par $M_n - \varepsilon < p < M_n + \varepsilon$ l'intervalle de confiance.

On a donc

$$\alpha = \frac{1}{4n\varepsilon^2} \text{ et } \varepsilon = \sqrt{\frac{1}{4n\alpha}}.$$

Sondage

- Un institut de sondage interroge 1000 personnes. On note p la probabilité de dire oui et p non.

Dans le sondage cette proportion est 0,54. On est intéressé par un interval de confiance pour p au niveau 0,95.

On a

$$\begin{aligned}M_{1000} &= 0,54 \\ I &= [0,54 - \varepsilon, 0,54 + \varepsilon] \\ \mathbb{P}(p \in I) &\geq 1 - \frac{1}{4 \cdot 1000 \cdot \varepsilon^2} = 1 - \alpha.\end{aligned}$$

Pour avoir un niveau de confiance de 0,95 on pose

$$\begin{aligned}1 - \frac{1}{4 \cdot 1000 \cdot \varepsilon^2} &\geq 0,95 \\ \frac{1}{4 \cdot 1000 \cdot \varepsilon^2} &\leq 0,05 \\ \varepsilon &\geq \sqrt{\frac{1}{200}} \simeq 0,0707.\end{aligned}$$

- On cherche n pour que $\varepsilon = 0,01$ et $1 - \alpha = 0,95$.
Donc

$$\begin{aligned} 1 - \frac{1}{4 \cdot n \cdot (0,01)^2} &\geq 0,95 \\ \frac{1}{4 \cdot n \cdot (0,01)^2} &\leq 0,05 \\ n &\geq \frac{1}{4 \cdot 0,05 \cdot (0,01)^2} \\ &= 50.000 \end{aligned}$$

8.2 Version forte de la LGN

Théorème 105 Soit $(X_n)_n$ une suite de variables aléatoires indépendantes et de même loi (i.i.d.) avec un moment d'ordre un (i.e. $\mathbb{E}(|X_1|) < \infty$, si l'espérance est bien définie). Alors

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p.s.} \mathbb{E}(X_1), \quad \text{pour } n \rightarrow \infty.$$

8.2.1 Estimateurs

Si X est une variable aléatoire, on appelle échantillon indépendant de la loi de X la suite $(X_i)_i$ qui est i.i.d. de même loi que X . On définit

- la moyenne empirique $M_n = \frac{1}{n} \sum_{k=1}^n X_k$
- la variance empirique $V_n = \frac{1}{n} \sum_{k=1}^n (X_k - M_n)^2$

Proposition 106 Les estimateurs M_n et V_n sont consistants pour $\mathbb{E}(X)$ et $V(X)$ i.e.

$$\begin{aligned} M_n &\xrightarrow{p.s.} \mathbb{E}(X), \quad \text{pour } n \rightarrow \infty \\ V_n &\xrightarrow{p.s.} V(X), \quad \text{pour } n \rightarrow \infty. \end{aligned}$$

Démonstration. On a

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p.s.} \mathbb{E}(X), \quad \text{pour } n \rightarrow \infty \text{ par LGN}$$

et donc

$$M_n \xrightarrow{p.s.} \mathbb{E}(X), \quad \text{pour } n \rightarrow \infty.$$

Pour la variance on a

$$\begin{aligned} V_n &= \frac{1}{n} \left(\sum_{k=1}^n (X_k^2 - 2X_k M_n + M_n^2) \right) \\ &= \frac{1}{n} \left(\sum_{k=1}^n X_k^2 - 2M_n \sum_{k=1}^n X_k + nM_n^2 \right) \\ &= \frac{1}{n} \left(\sum_{k=1}^n X_k^2 - 2nM_n^2 + nM_n^2 \right) \\ &= \frac{1}{n} \left(\sum_{k=1}^n X_k^2 - nM_n^2 \right) \\ &\simeq \mathbb{E}(X^2) - (\mathbb{E}(X))^2 = V(X) \end{aligned}$$

■

8.2.2 Méthode de Monte-Carlo

Soit $f : B \rightarrow \mathbb{R}^2$ et $(X_n)_n$ une suite de variables aléatoires i.i.d. uniformes sur B . On a

$$\frac{1}{n} \sum_{k=1}^n f(X_k) \xrightarrow{p.s.} \frac{1}{\lambda(B)} \int_B f(x) dx, \quad n \rightarrow \infty.$$

En effet

$$\begin{aligned} \mathbb{E}(f(X)) &= \int_{\mathbb{R}} f(x) d\mathbb{P}_X(x) \\ &= \int_{\mathbb{R}} f(x) \frac{1}{\lambda(B)} 1_B(x) dx \\ &= \frac{1}{\lambda(B)} \int_B f(x) dx. \end{aligned}$$

Donc on peut approcher l'intégrale en approchant $\mathbb{E}(f(X))$ par $\frac{1}{n} \sum_{k=1}^n f(X_k)$.

8.3 Version L^1 de la LGN

Soit $(X_n)_n$ une suite de variables aléatoires indépendantes.

On note $S_n = \sum_{k=1}^n X_k$ la somme et on étudie la convergence de ces quantités quand $n \rightarrow \infty$.

Proposition 107 Si $(X_n)_n$ est une suite de variables aléatoires indépendantes, alors on a

$$S_n \text{ converge p.s.} \Leftrightarrow S_n \text{ converge en probabilité.}$$

Proposition 108 Soit $(X_n)_n$ une suite de variables aléatoires indépendantes centrées, de carrés intégrables. Alors on a

$$\mathbb{P} \left(\max_{1 \leq k \leq n} |S_k| > \alpha \right) \leq \frac{\mathbb{E} |S_n^2|}{\alpha^2}.$$

Cette inégalité est meilleure que celle de Tchebychev appliquée à S_n qui donne

$$\mathbb{P}(|S_n| > \alpha) \leq \frac{\mathbb{E} |S_n^2|}{\alpha^2}.$$

Proposition 109 Soit $(X_n)_n$ une suite de variables aléatoires indépendantes centrées, de L^2 . Si $\sum_n \mathbb{E} |X_n^2| < \infty$ alors S_n converge p.s.

Proposition 110 Soit $(X_n)_n$ une suite de variables aléatoires indépendantes centrées, de L^2 et $a_n > 0$ des réels qui convergent en croissant vers $+\infty$. Alors si $\sum_{n=1}^{\infty} \frac{\mathbb{E} |X_n^2|}{a_n^2} < \infty$ on a $\frac{S_n}{a_n} \xrightarrow[p.s., L^2]{} 0$.

Théorème 111 Soit $(X_n)_n$ une suite de variables aléatoires indépendantes et de même loi (v.a.i.i.d.) dans L^1 . Alors

$$\frac{S_n}{n} \xrightarrow{L^1} \mathbb{E} [X_1].$$

Chapitre 9

Théorème limite centrale

9.1 Fonction caractéristique

Définition 112 Soit X une variable aléatoire. On appelle fonction caractéristique une fonction de \mathbb{R} dans \mathbb{C}

$$\Phi_X(t) = \mathbb{E}(e^{itX}).$$

Remarque 113 Si X est une variable aléatoire discrète avec $X(\Omega) = \{x_1, x_2, \dots, x_n\}$, alors on a

$$\Phi_X(t) = \sum_{k=1}^n e^{itx_k} \mathbb{P}(X = x_k).$$

Si X est une variable aléatoire à densité, alors on a

$$\begin{aligned} \Phi_X(t) &= \int_{\Omega} e^{itX} d\mathbb{P} \\ &= \int_{\mathbb{R}} e^{itx} d\mathbb{P}_X(x) \\ &= \int_{\mathbb{R}} e^{itx} f(x) dx \end{aligned}$$

Proposition 114 La fonction caractéristique caractérise la loi. Donc si $\Phi_X = \Phi_Y$ alors les variables aléatoires X et Y ont la même loi et réciproquement.

Proposition 115 Si on a deux variables aléatoires indépendantes X et Y alors

$$\Phi_{X+Y}(t) = \Phi_X(t) \Phi_Y(t).$$

Démonstration. On voit facilement que

$$\Phi_{X+Y}(t) = \mathbb{E} \left(e^{it(X+Y)} \right) = \mathbb{E} \left(e^{itX} \right) \mathbb{E} \left(e^{itY} \right) = \Phi_X(t) \Phi_Y(t).$$

■

Définition 116 Soit (X, Y) un vecteur aléatoire. On définit la fonction caractéristique comme une fonction de \mathbb{R}^2 dans \mathbb{C}

$$\begin{aligned} \Phi_{(X,Y)}(t, s) &= \mathbb{E} \left(e^{i\langle (t,s), (X,Y) \rangle} \right) \\ &= \mathbb{E} \left(e^{i(tX+sY)} \right). \end{aligned}$$

Proposition 117 Deux variables aléatoires sont indépendantes si et seulement si

$$\Phi_{(X,Y)}(t, s) = \Phi_X(t) \Phi_Y(s).$$

Démonstration. On a

$$\begin{aligned} X \text{ et } Y \text{ indép} &\Leftrightarrow \mathbb{P}_{(X,Y)} = \mathbb{P}_X \mathbb{P}_Y \\ &\Leftrightarrow \int_{\mathbb{R}^2} e^{itx+isy} d\mathbb{P}_{(X,Y)} = \int_{\mathbb{R}^2} e^{itx+isy} d\mathbb{P}_X \mathbb{P}_Y \\ &\Leftrightarrow \Phi_{(X,Y)}(t, s) = \Phi_X(t) \Phi_Y(s). \end{aligned}$$

■

Théorème 118 (Paul Lévy) La convergence en loi des variables aléatoires est équivalente à la convergence simple de leur fonction caractéristique.

Démonstration. \Rightarrow On sait que

$$\mathbb{P}_{X_n} \rightarrow \mathbb{P}_X \text{ pour } n \rightarrow \infty$$

signifie

$$\mathbb{E}(f(X_n)) \rightarrow \mathbb{E}(f(X)) \text{ pour } \forall f \in C_b(\mathbb{R}) \text{ quand } n \rightarrow \infty.$$

On choisi $f(x) = e^{itx}$ et on obtient

$$\mathbb{E}(e^{itX_n}) \rightarrow \mathbb{E}(e^{itX}) \text{ quand } n \rightarrow \infty$$

et donc

$$\Phi_{X_n}(t) \rightarrow \Phi_X(t).$$

■

9.2 Variables et vecteurs gaussiens

Définition 119 Une variable aléatoire X suit la loi normale standard $N(0, 1)$ si elle admet la densité

$$f(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}.$$

Plus générale, une variable aléatoire X suit la loi normale $N(m, \sigma^2)$ si elle admet la densité

$$f(t) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(t-m)^2/2\sigma^2}.$$

Proposition 120 Si $X_0 \hookrightarrow N(0, 1)$ alors $X = m + \sigma X_0 \hookrightarrow N(m, \sigma^2)$ et si $X \hookrightarrow N(m, \sigma^2)$ alors $X_0 = \frac{X - m}{\sigma} \hookrightarrow N(0, 1)$.

Proposition 121 Une variable aléatoire X de loi $N(m, \sigma^2)$ a l'espérance $\mathbb{E}(X) = m$, la variance $V(X) = \sigma^2$ et la fonction caractéristique $\Phi_X(t) = \exp(imt - \sigma^2 t^2/2)$.

Par contre, une variable aléatoire qui a l'espérance $\mathbb{E}(X) = m$ et la variance $V(X) = \sigma^2$ n'est pas forcément de loi normale.

Si une variable aléatoire a la fonction caractéristique $\Phi_X(t) = \exp(imt - \sigma^2 t^2/2)$ alors elle suit une loi normale $N(m, \sigma^2)$.

Proposition 122 Soient $X_1 \hookrightarrow N(m_1, \sigma_1^2)$ et $X_2 \hookrightarrow N(m_2, \sigma_2^2)$ indépendantes. Alors $X_1 + X_2 \hookrightarrow N(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$.

Définition 123 Un vecteur aléatoire $X = (X_1, X_2, \dots, X_n)$ est gaussien si et seulement si toutes les combinaisons linéaires de ces coordonnées $\langle a, X \rangle = a_1 X_1 + \dots + a_n X_n$ suit une loi gaussienne dans \mathbb{R} , pour tout $a \in \mathbb{R}^n$.

Remarque 124 Si $X = (X_1, X_2, \dots, X_n)$ est un vecteur aléatoire gaussien alors $\langle a, X \rangle$ suit une loi normale de paramètres

$$\begin{aligned} \mathbb{E}(\langle a, X \rangle) &= \mathbb{E}(a_1 X_1 + \dots + a_n X_n) \\ &= \langle a, \mathbb{E}(X) \rangle \end{aligned}$$

$$\begin{aligned}
V(\langle a, X \rangle) &= V(a_1 X_1 + \dots + a_n X_n) \\
&= \sum_{i,j=1}^n a_i a_j \text{Cov}(X_i, X_j) \\
&= a^t \text{Cov}(X_i, X_j) a.
\end{aligned}$$

Donc $\langle a, X \rangle$ suit une loi $N(\langle a, \mathbb{E}(X) \rangle, a^t \text{Cov}(X_i, X_j) a)$ et sa fonction caractéristique est

$$\Phi_{\langle a, X \rangle}(x) = \exp \left(i x \langle a, \mathbb{E}(X) \rangle - \frac{1}{2} (a^t \text{Cov}(X_i, X_j) a) x^2 \right).$$

Proposition 125 La fonction caractéristique d'un vecteur gaussien $X = (X_1, X_2, \dots, X_n)$ est donné par

$$\Phi_X(x) = \exp \left(i \langle x, \mathbb{E}(X) \rangle - \frac{1}{2} (x^t \text{Cov}(X_i, X_j) x) \right).$$

Proposition 126 Soient (X, Y) un couple gaussien. Alors X et Y sont indépendantes si et seulement si $\text{Cov}(X, Y) = 0$.

Le sens direct est vrai quelque soit la loi de X et Y . La réciproque non.

9.3 Théorème limite centrale

Théorème 127 Soit $(X_n)_n$ une suite de variables aléatoires indépendantes et de même loi, d'espérance m et de variance σ^2 . Soit $S_n = X_1 + \dots + X_n$ la somme partielle. Alors quand $n \rightarrow \infty$

$$\frac{S_n - nm}{\sigma \sqrt{n}} \xrightarrow{\mathcal{L}} N(0, 1).$$

Démonstration. Soit $Y_i = X_i - m$.

Alors les variables Y_i sont indépendantes de même loi avec

$$\mathbb{E}(Y_i) = 0 \text{ et } V(Y_i) = V(X_i).$$

Notons

$$S'_n = Y_1 + \dots + Y_n = S_n - nm$$

et

$$Z_n = \frac{S_n - nm}{\sigma \sqrt{n}} = \frac{S'_n}{\sigma \sqrt{n}}.$$

On a

$$\begin{aligned}
\Phi_{Z_n}(t) &= \mathbb{E}(e^{itZ_n}) \\
&= \mathbb{E}\left(e^{it \frac{S'_n}{\sigma\sqrt{n}}}\right) \\
&= \Phi_{S'_n}\left(\frac{t}{\sigma\sqrt{n}}\right) \\
&= \Phi_{Y_1}\left(\frac{t}{\sigma\sqrt{n}}\right) \Phi_{Y_2}\left(\frac{t}{\sigma\sqrt{n}}\right) \dots \Phi_{Y_n}\left(\frac{t}{\sigma\sqrt{n}}\right) \\
&= \left(\Phi_{Y_1}\left(\frac{t}{\sigma\sqrt{n}}\right)\right)^n
\end{aligned}$$

et

$$\Phi_{Y_1}(x) = \Phi_{Y_1}(0) + x\Phi'_{Y_1}(0) + \frac{x^2}{2}\Phi''_{Y_1}(0) + x^2\varepsilon(x).$$

On calcule

$$\begin{aligned}
\Phi_{Y_1}(0) &= 1 \\
\Phi'_{Y_1}(0) &= i\mathbb{E}(Y_1) = 0 \\
\Phi''_{Y_1}(0) &= (i)^2 \mathbb{E}(Y_1^2) = -\sigma^2.
\end{aligned}$$

Donc

$$\begin{aligned}
\Phi_{Z_n}(t) &= \left(1 - \frac{\sigma^2}{2} \frac{t^2}{n\sigma^2} + \frac{t^2}{n\sigma^2} \varepsilon\left(\frac{t}{\sqrt{n}\sigma}\right)\right)^n \\
&= \left(1 - \frac{t^2}{2n} + \frac{1}{n} \varepsilon\left(\frac{1}{\sqrt{n}}\right)\right)^n \\
&= e^{\ln\left(1 - \frac{t^2}{2n} + \frac{1}{n} \varepsilon\left(\frac{1}{\sqrt{n}}\right)\right)^n} \\
&= e^{n \ln\left(1 - \frac{t^2}{2n} + \frac{1}{n} \varepsilon\left(\frac{1}{\sqrt{n}}\right)\right)} \\
&\sim e^{n \left(1 - \frac{t^2}{2n} + \frac{1}{n} \varepsilon\left(\frac{1}{\sqrt{n}}\right)\right)} \\
&= e^{-\frac{t^2}{2} + \varepsilon\left(\frac{1}{\sqrt{n}}\right)}.
\end{aligned}$$

On a

$$\Phi_{Z_n}(t) \simeq e^{-\frac{t^2}{2} + \varepsilon\left(\frac{1}{\sqrt{n}}\right)} \rightarrow e^{-\frac{t^2}{2}}.$$

Donc $Z_n \rightarrow N(0, 1)$ converge p.s. ■

Exemple 128 On lance une pièce et lorsqu'il obtient pile on gagne 100 euro et lorsqu'il obtient face, il perd 100 euro.

Il faut estimer le nombre maximal de lancers à effectuer pour avoir plus de 95% de ne pas perdre plus de 2000 euro.

On note par n le nombre de lancers effectués.

La variable aléatoire S_n qui est égale au nombre de piles obtenus sur les n premiers lancers, suit une loi $B(n, 1/2)$ et le gain vaut :

$$\begin{aligned} G_n &= 100 \times S_n - 100 \times (n - S_n) \\ &= 200S_n - 100n. \end{aligned}$$

On cherche alors n tel que

$$\mathbb{P}(G_n \geq -2000) \geq 0,95.$$

Or

$$\{G_n \geq -2000\} = \{S_n - n/2 \geq -10\}.$$

Comme S_n qui suit une loi binomiale peut être vue comme une somme

$$S_n = \epsilon_1 + \dots + \epsilon_n$$

de variables aléatoires de loi $b(1/2)$ de Bernoulli.

On calcule

$$\begin{aligned} \mathbb{E}(S_n) &= \frac{n}{2} \\ V(S_n) &= \frac{n}{4}. \end{aligned}$$

D'après le TCL on a

$$S_n^* = \frac{S_n - \frac{n}{2}}{\frac{\sqrt{n}}{2}} \hookrightarrow N(0, 1).$$

On calcule

$$\mathbb{P}(G_n \geq -2000) \geq 0,95$$

$$\begin{aligned} \Leftrightarrow \mathbb{P}\left(\frac{S_n - \frac{n}{2}}{\frac{\sqrt{n}}{2}} \geq \frac{-10}{\frac{\sqrt{n}}{2}}\right) &\geq 0,95 \\ \Leftrightarrow \mathbb{P}\left(N(0, 1) < \frac{20}{\sqrt{n}}\right) &\geq 0,95. \end{aligned}$$

On obtient $n = 146$.

Chapitre 10

Temps d'arrêt

Définition 129 Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité. Une suite croissante $(\mathcal{F}_n)_n$ de sous- σ -algèbre de \mathcal{F} est appelée filtration. L'espace $(\Omega, \mathcal{F}, (\mathcal{F}_n)_n, \mathbb{P})$ est donc un espace filtré.

Définition 130 Soit $(X_n)_{n \in \mathbb{N}}$ un processus stochastique. On dit que $(X_n)_{n \in \mathbb{N}}$ est \mathcal{F}_n -adapté si pour tout n on a que X_n est \mathcal{F}_n -mesurable.

Soit $(\Omega, \mathcal{F}, (\mathcal{F}_n)_n, \mathbb{P})$ un espace de probabilité filtré.

Définition 131 Une variable aléatoire $T : \Omega \rightarrow \mathbb{N}$ est appelée temps d'arrêt si pour tout $n \in \mathbb{N}$, on a

$$\begin{aligned} \{T = n\} &\in \mathcal{F}_n \iff \{T \leq n\} \in \mathcal{F}_n \\ &\iff \{T \geq n\} \in \mathcal{F}_n. \end{aligned}$$

Exemple 132

- 1) Le temps constant $T = k$, pour $k \in \mathbb{N}$ est un temps d'arrêt.
- 2) Soit $\{X_n\}$ un processus stochastique discret adapté à la filtration $\{\mathcal{F}_n, n \geq 0\}$. Pour $A \in \mathcal{B}(\mathbb{R})$ on définit

$$T_A = \begin{cases} \inf \{n \in \mathbb{N} \mid X_n \in A\}, & \text{si } A \neq \emptyset \\ \infty, & \text{sinon} \end{cases}$$

C'est un temps d'arrêt appelé "temps d'entrée dans A ".
On voit que

$$\{T_A = n\} = \{X_0 \notin A, X_1 \notin A, \dots, X_n \in A\} \in \mathcal{F}_n$$

$$X_0^{-1}(A^c) \cap X_1^{-1}(A^c) \cap \dots \cap X_n^{-1}(A^c) \in \mathcal{F}_n$$

car $(\mathcal{F}_n)_n$ est une filtration, $A \in \mathcal{B}(\mathbb{R})$ et $\{X_n\}$ est adapté.

Proposition 133

- 1) Soit S et T deux temps d'arrêt. Alors $S + T$, $S \wedge T$ et $S \vee T$ sont aussi des temps d'arrêt.
- 2) Soit T deux temps d'arrêt. On définit

$$\mathcal{F}_T = \{A \mid A \cap \{T \leq n\} \in \mathcal{F}_n, \forall n \geq 0\}.$$

On montre que \mathcal{F}_T est une tribu (σ -algèbre).

- $\emptyset, \Omega \in \mathcal{F}_T$
- $A^c \cap \{T \leq n\} = (A \cup \{T > n\})^c = ((A \cap \{T \leq n\}) \cup \{T > n\})^c \in \mathcal{F}_n$
car

$$A = (A \cap \{T \leq n\}) \cup (A \cap \{T > n\})$$

et

$$A \cap \{T > n\} \subset \{T > n\}.$$

On obtient donc $A^c \cap \{T \leq n\} \in \mathcal{F}_n \implies A^c \in \mathcal{F}_T$.

- A et $B \in \mathcal{F}_T$

$$(A \cup B) \cap \{T \leq n\} = \underbrace{(A \cap \{T \leq n\})}_{\in \mathcal{F}_n} \cup \underbrace{(B \cap \{T \leq n\})}_{\in \mathcal{F}_n}$$

(Sur \mathcal{F}_n on sait que c'est une σ -algèbre et on utilise ses propriétés).

- 3) Pour \mathcal{F}_T définies avant on a que $S \leq T$ alors $\mathcal{F}_S \subset \mathcal{F}_T$.

On sait que $\{T \leq n\} \subset \{S \leq n\}$ car

$$\begin{aligned} \omega &\in \{T \leq n\} \implies T(\omega) \leq n \\ &\implies S(\omega) \leq T(\omega) \leq n \\ &\implies \omega \in \{S \leq n\}. \end{aligned}$$

Donc

$$A \cap \{T \leq n\} = \underbrace{A \cap \{S \leq n\}}_{\in \mathcal{F}_n} \cap \underbrace{\{T \leq n\}}_{\in \mathcal{F}_n}$$

$$A \cap \{T \leq n\} \in \mathcal{F}_n \implies A \in \mathcal{F}_T.$$

Bibliographie

- [1] Jean-Christophe Breton "*Cours de probabilités*"
- [2] Sébastien Martineau "*Cours de probabilités*"
- [3] Bruno Saussereau "*Cours de théorie des probabilités avec exercices corrigés et devoirs*"