

Mini tutoriel R pour l'analyse de données

Jean-Marc Lasgouttes — Inria Paris

Jean-Marc.Lasgouttes@inria.fr

<http://ana-donnees.lasgouttes.net/>

Qu'est-ce que R ? _____

Une copie de S S est un logiciel de statistiques développé aux Bell Labs ; R est une implémentation libre distribuée sous la licence GNU GPL.

Un logiciel populaire beaucoup de fonctionnalités ont été développées par la communauté R ; c'est sa grande force.

Un logiciel portable R existe sous Windows, macOS et Linux.

Un logiciel libre Le code source de R et des binaires sont disponibles sur <https://cran.org/>

CRAN ? C'est le site qui regroupe tous les *packages* R développés par la communauté

Analyse de données en R _____

Dans ce cours : ade4

- disponible sur CRAN
- développé à l'université Lyon I

Autres possibilités

- livré avec R : fonction `prcomp` pour l'ACP ou `corresp` (du package MASS) pour l'AFC
Assez basique
- package `FactoMineR` : peut-être plus moderne

IDE RStudio Environnement de travail, installé sur vos machines

- console R pour taper les commandes
- panneaux pour visualiser les variables, les tables, les graphiques
- possibilité de faire des *notebooks* en langage markdown combinées à du code R.

Lire des données _____

Commande de base

```
read.table(file, header = FALSE, sep = ",",
  quote = "\"'", dec = ".", numerals = c(...),
  row.names, col.names,
  as.is = !stringsAsFactors, na.strings = "NA",
  colClasses = NA, nrows = -1, skip = 0,
  check.names = TRUE, fill = !blank.lines.skip,
  strip.white = FALSE, blank.lines.skip = TRUE,
  comment.char = "#",
  allowEscapes = FALSE, flush = FALSE,
  stringsAsFactors = FALSE,
  fileEncoding = "", encoding = "unknown", text, skipNul = FALSE)
```

Comment lire ça ?

- les paramètres peuvent avoir une valeur par défaut (FALSE pour `header`)
Seules les quelques premières sont obligatoires
- si on ne donne pas le nom, ce sera le premier, le second...
- on peut abrégier le nom si ce n'est pas ambigu (`head` pour `header`, par ex.)
- en général, on ne donne que quelques paramètres

Lire des données (suite) _____

Commande de base version courte

```
read.table(file, header = FALSE, sep = ",",
  quote = "\"'", ...)
```

Explications afficher l'aide avec la commande `?read.table` ou `help(read.table)`

Et le résultat ? uniquement retour de fonction (souvent un objet complexe)

On peut afficher l'objet avec la commande `print(obj)` (ou juste `obj`) ou alors `summary(obj)`

Exemple parfois aussi simple que

```
sympa <- read.table("sympa.txt")
```

« <- » ?? C'est l'opérateur d'affectation (on peut aussi utiliser =)

Autre type de fichiers

- comma separated variables (csv) : `read.csv()`, `read.csv2()`
- libreoffice calc avec `read_ods()` du package `readODS`

Manipuler une table _____

Comme un tableau

- `sympa[3,2]` donne la case de troisième ligne et seconde colonne
- `sympa["PAYS",]` donne la ligne correspondant à PAYS
- `sympa[1,]` pareil (PAYS est la première ligne)
- `sympa[1:3,2:4]` donne le bloc composé des lignes 1 à 3 et des colonnes 2 à 4

Comme un enregistrement en utilisant `$` pour accéder à un champ

- `sympa$GENE` donne la colonne correspondant à la colonne GENE (sans les noms de ligne/colonnes)

Type de données connues de R

- réels, entiers, booléens (TRUE ou FALSE) ou facteurs (valeurs qualitatives)
- vecteur de ces variables `c(3,2, 1.5, FALSE)`
- matrice à deux dimensions

```
matrix(c(1,2,3, 11,12,13),  
       nrow=2, ncol=3, byrow=TRUE)
```

$$\begin{pmatrix} 1 & 2 & 3 \\ 11 & 12 & 13 \end{pmatrix}$$

Utiliser ade4

Installer le package à faire une seule fois

```
install.packages("ade4")
```

ou alors dans RStudio le menu « Tools » Install Package ».

Charger le package là, plus besoin de guillemets

```
require(ade4)
```

Concept central de ade4 Duality diagram (DUDI)

Faire une AFC

AFC COrrispondance Analysis

```
dudi.coa(df, scannf = TRUE, nf = 2)
```

Paramètres

- `df` : les données comme retournées par `read.table` (data frame)
- `scannf` : si vrai (TRUE ou T), affiche un graphique des valeurs propres et demande le nombre d'axes à conserver
- `nf` : quand `scannf=F`, contient le nombre d'axes à conserver

Exemple typique

```
coa1 <- dudi.coa(mesdonnees, scannf = F, nf = 4)
```

L'objet `coa1` a, entre autres champs

- `coa1$eig` : valeurs propres
- `coa1$co`, `coa1$li` : coordonnées des colonnes et des lignes
- `coa1$cw`, `coa1$lw` : poids des colonnes et des lignes

Mais aussi... une ACP avec `dudi.pca()` et une ACM avec `dudi.acm()`

Des graphiques !

Les valeurs propres

```
barplot(coa1$eig)
```

La projection des individus on affiche les modalités de colonne du premier plan avec

```
s.label(coa1$co)
```

et on ajoute les modalités de ligne avec

```
s.label(coa1$li, add.plot=T)
```

Paramètres `s.label(x, xax=1, yax=2, add.plot=F, ...)`

- `x` : objet renvoyé par `dudi.coa`
- `xax`, `yax` : indice de l'axe principal en abscisse, ordonnée
- `add.plot=T` indique que les nouveaux points seront sur le graphe préexistant

Données liées à l'inertie

Commande de base calcul de l'inertie totale et autres

```
inert1 <- inertia(x, row.inertia = FALSE,  
                 col.inertia = FALSE)
```

- `x` : objet retourné par `dudi.coa`
- `row.inertia` : calculs détaillés par ligne
- `col.inertia` : calculs détaillés par colonne

Valeur retournée objet avec les champs

- `tot.inertia` : répartition de l'inertie entre les axes
- `row.contrib` : contribution des lignes aux axes
- `row.rel` : qualité de représentation par les axes
- `row.cum` : qualité de représentation cumulée par les axes
- et les mêmes avec `col.xxx` pour les colonnes