

# Cours 7 – Estimation dans le cadre de l'échantillon gaussien.

*Eya ZOUGAR \**

*Institut National des Sciences appliquées-INSA*

Génie mathématiques GM3  
Thursday 9<sup>th</sup> March, 2023



---

\*Basé sur le cours de Bruno PORTIER

# 1. Introduction : cadre et objectif.

On dispose de  $n$  données réelles  $x_1, x_2, \dots, x_n$ .

On suppose que ces données sont les réalisations de  $n$  variables aléatoires réelles  $X_1, X_2, \dots, X_n$ , indépendantes et de même loi normale  $\mathcal{N}(\mu, \sigma^2)$ .

On s'intéresse à l'estimation des paramètres d'espérance  $\mu$  et de variance  $\sigma^2$  supposés inconnus.

Il est facile d'estimer ces paramètres, mais le fait de se placer dans le cadre gaussien, va nous permettre de préciser la loi des estimateurs pour toute taille  $n$  de l'échantillon.

Nous allons en particulier pouvoir établir des résultats importants qui seront à la base de tests statistiques utiles.

## 2. Rappels sur quelques lois utiles.

### 2.1. Le vecteur gaussien.

Soit  $Z$  un vecteur gaussien de  $\mathbb{R}^n$ , d'espérance le vecteur  $\mu$  de  $\mathbb{R}^n$ , et de matrice de variance-covariance  $\Gamma$ , qu'on note  $Z \sim \mathcal{N}(\mu, \Gamma)$ .

On notera que la matrice  $\Gamma$  est définie positive, donc inversible.

La densité de probabilité  $f$  de  $Z$  est une fonction de  $\mathbb{R}^n$  dans  $\mathbb{R}_+$ .

Elle est définie pour tout  $z \in \mathbb{R}^n$  par :

$$f(z) = \frac{1}{\sqrt{(2\pi)^n \det(\Gamma)}} \exp \left( -\frac{1}{2} (z - \mu)^T \Gamma^{-1} (z - \mu) \right)$$

## 2.2. La variable gaussienne.

Dans le cas pour  $n = 1$  : Si  $Z \sim \mathcal{N}(\mu, \sigma^2)$

$$f(z) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z-\mu)^2}{2\sigma^2}\right)$$

## 2.2. La variable gaussienne.

Dans le cas pour  $n = 1$  : Si  $Z \sim \mathcal{N}(\mu, \sigma^2)$

$$f(z) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z-\mu)^2}{2\sigma^2}\right)$$

### Lemme

Si  $Z \sim \mathcal{N}(\mu, \sigma^2)$  alors  $\frac{Z-\mu}{\sigma} \sim \mathcal{N}(0, 1)$

## 2.2. La variable gaussienne.

Dans le cas pour  $n = 1$  : Si  $Z \sim \mathcal{N}(\mu, \sigma^2)$

$$f(z) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z-\mu)^2}{2\sigma^2}\right)$$

### Lemme

Si  $Z \sim \mathcal{N}(\mu, \sigma^2)$  alors  $\frac{Z-\mu}{\sigma} \sim \mathcal{N}(0, 1)$

### Moment d'ordre n

Si  $Z \sim \mathcal{N}(\mu, \sigma^2)$  alors  $\mathbb{E}[(Z-\mu)^n] = m_n$  est donné par:

$$\begin{cases} m_{2k+1} = 0 & \text{si } n=2k+1 \\ m_{2k} = \frac{(2k)!}{2^k k!} \sigma^{2k} & \text{si } n=2k \end{cases}$$



## 2.3. R code

On trouvera ci-dessous le code R permettant de réaliser les figures du slide suivant.

```
# Construction de courbes de densité avec quantiles à 95%
polycurve <- function(x, y, base.y = min(y), ...) {
  polygon(x = c(min(x), x, max(x)), y = c(base.y, y, base.y), ...)
}

pdf("Gaussienne_Graphe.pdf")
x = seq(-4,4,l=200)
d0 = dnorm(x)
d1 = dnorm(x,sd=0.8)
d2 = dnorm(x,sd=1.2)
d3 = dnorm(x,m=-2.5)
matplot(cbind(x,x,x,x),cbind(d0,d1,d2,d3),type="l",lty=1,lwd=3,
        xlab="x",ylab="f(x)",cex.axis=1.4,cex.lab=1.4,
        main="Densités gaussiennes",cex.main=1.5)
xxx=dev.off()
```

```
pdf("Gaussienne_Quantile.pdf")
plot(x,d0,type="l",xaxt="n",xlab="x",ylab="f(x)",cex.axis=1.4,
     cex.lab=1.4,main="Densité gaussienne centrée réduite",cex.main=1.5)
axis(1,at=c(-4,-1.96,0,1.96,4),lab=c("-4","-1.96","0","1.96","4"),
     cex.axis=1.4)
polycurve(xx,yy,0,density=8,angle=45,lwd=2.5)
lines(x,d0,lwd=3)
abline(h=0)
xxx=dev.off()
```







## 2.4 Loi du Khi-deux.

On appelle loi du chi-deux à  $p$  degrés de liberté (ddl) la loi de la variable  $Z = \sum_{j=1}^p X_j^2$  où les variables  $X_1, X_2, \dots, X_p$ ,  $p \geq 1$  sont des variables aléatoires indépendantes et de même loi  $\mathcal{N}(0, 1)$ . On a de plus,  $\mathbb{E}[Z] = p$  et  $\text{Var}[Z] = 2p$ .

Densités du Khi2





Densité du Khi2 à 6 ddl



## 2.5. Loi de Student.

On appelle loi de Student à  $n$  degrés de liberté, le rapport d'une gaussienne centrée réduite et de la racine carrée d'un khi-deux à  $n$  degrés de liberté, la gaussienne et le khi-deux étant indépendants.

**Plus précisément,** si  $U \sim \mathcal{N}(0, 1)$  et  $V \sim \chi_n^2$  avec  $U$  et  $V$  indépendantes, alors  $Z_n = \frac{U}{\sqrt{V/n}}$  suit une loi de Student à  $n$  ddl et on note  $Z \sim T_n$  et on a  $\mathbb{E}(Z_n) = 0$  et  $Z_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1)$ .



# Lemme de Slutsky.

Soient  $(X_n)_{n \geq 1}$  et  $(Y_n)_{n \geq 1}$  deux suites de variables aléatoires réelles.

S'il existe une variable aléatoire  $X$  et une constante non nulle  $a$  telles que

$$X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} X$$

$$Y_n \xrightarrow[n \rightarrow \infty]{P} a$$

alors

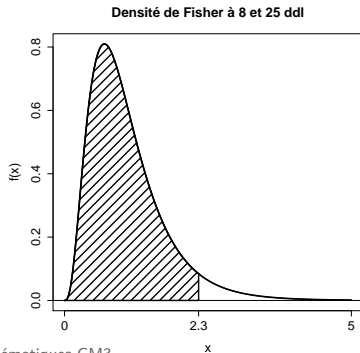
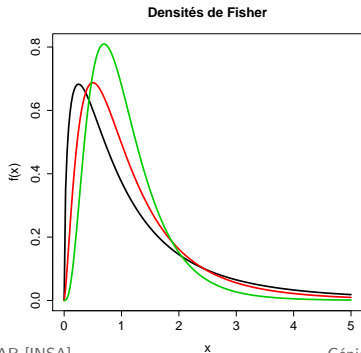
$$Y_n X_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}} aX$$

## 2.6. Loi de Fisher.

On appelle loi de Fisher à  $p$  et  $q$  degrés de liberté le rapport de 2 khi-deux indépendants à  $p$  et  $q$  degrés de libertés respectivement.

**Plus précisément,** si  $U \sim \chi_p^2$  et  $V \sim \chi_q^2$  avec  $U$  et  $V$

indépendantes, alors  $Z = \frac{U/p}{V/q}$  suit une loi de Fisher à  $p$  et  $q$  ddl et on note  $Z \sim F(p, q)$ .



### 3. Théorème de Cochran

#### 3.1. Un premier Théorème.

**Rappel.** Si  $Z$  est un vecteur gaussien centré et réduit, c'est-à-dire si  $Z \sim \mathcal{N}(0, I_n)$ , alors  $\|Z\|^2 \sim \chi^2(n)$ .

En effet,  $\|Z\|^2 = \sum_{j=1}^n Z_j^2$  est une somme de  $n$  gaussiennes indépendantes, centrées réduites élevées au carré, c'est donc par définition un khi-deux à  $n$  degrés de liberté (ddl).

On a par ailleurs le théorème suivant :

#### Théorème

Si

- $Z \sim \mathcal{N}(0, I_n)$
- $P_E$  est un projecteur orthogonal de  $\mathbb{R}^n$  sur un sous-espace vectoriel  $E$  de dimension  $p$

alors  $\|P_E(Z)\|^2$  suit une loi  $\chi^2(p)$ .

## 3.2. Le Théorème de Cochran.

### Théorème de Cochran

Soient  $E_1$  et  $E_2$  deux sous-espaces vectoriels orthogonaux de  $\mathbb{R}^n$ , de dimensions respectives  $p_1$  et  $p_2$ , et soit  $Z$  un vecteur gaussien de  $\mathbb{R}^n$ , centré et de matrice de variance-covariance  $I_n$ .

Alors,

- ❑  $\|P_{E_1}(Z)\|^2$  suit une loi  $\chi^2(p_1)$
- ❑  $\|P_{E_2}(Z)\|^2$  suit une loi  $\chi^2(p_2)$
- ❑ les variables aléatoires  $\|P_{E_1}(Z)\|^2$  et  $\|P_{E_2}(Z)\|^2$  sont indépendantes

**Remarque.** Ce théorème se généralise au cas de  $2 \leq m \leq n$  sous-espaces vectoriels orthogonaux  $(E_i)_{1 \leq i \leq m}$  de  $E$ .

### 3.3. Le corollaire de Cochran.

On déduit du théorème précédent, le corollaire suivant, qui nous sera utile dans le cas de l'échantillon gaussien pour étudier la loi des différents estimateurs.

#### Corollaire de Cochran.

Soit  $n \geq p$ . Soit  $E$  un sous-espace vectoriel de  $\mathbb{R}^n$  de dimension  $p$ , et soit  $Z$  un vecteur gaussien de  $\mathbb{R}^n$ , centré et de matrice de variance-covariance  $I_n$ .

Alors, on a

$$\|Z\|^2 = \|P_E(Z)\|^2 + \|Z - P_E(Z)\|^2$$

et

- ❑  $\|P_E(Z)\|^2$  suit une loi  $\chi^2(p)$
- ❑  $\|Z - P_E(Z)\|^2$  suit une loi  $\chi^2(n - p)$
- ❑  $\|P_E(Z)\|^2$  et  $\|Z - P_E(Z)\|^2$  sont indépendantes

## 4. Estimation des paramètres.

### 2.1. Définition des estimateurs.

Puisque  $\mu = \mathbb{E}(X_1)$  et  $\sigma^2 = \mathbb{V}\text{ar}(X_1)$ , on peut estimer le paramètre de moyenne  $\mu$  par:

$$\bar{X}_n = \frac{1}{n} \sum_{j=1}^n X_j$$

et le paramètre de variance par:

$$S^2 = \frac{1}{(n-1)} \sum_{j=1}^n (X_j - \bar{X}_n)^2$$

On sait que, dans le cas de variables aléatoires  $(X_j)$  indépendantes et de même loi, ces estimateurs sont sans biais et convergents.

Cependant, dans le cas de l'échantillon gaussien, on peut préciser leur loi pour toute taille d'échantillon  $n$ .



## 4.2. Propriétés.

On a les résultats suivants:

### Theorem

$$\square \bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

$$\square \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

$$\square \bar{X}_n \text{ et } S^2 \text{ sont indépendants.}$$

où  $\chi_q^2$  désigne la loi du khi-deux à  $q$  ddl.

### Corollaire

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{S} \sim T_{n-1}$$

où  $T_q$  désigne la loi de Student à  $q$  ddl.

## 2. Preuves des différents résultats.

### 2.1. Loi de $\bar{X}_n$ .

Puisque les variables  $X_1, X_2, \dots, X_n$  sont des variables gaussiennes indépendantes,  $\bar{X}_n$  est une combinaison linéaire de variables gaussiennes indépendantes et donc une variable gaussienne.

Par conséquent, on a :

$$\bar{X}_n \sim \mathcal{N}(\mathbb{E}(\bar{X}_n), \text{Var}(\bar{X}_n)).$$

Or, on a déjà montré que

$$\square \mathbb{E}[\bar{X}_n] = \mu ;$$

$$\square \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

Le résultat est ainsi établi.

## 2.2. Loi de $S^2$ .

### 2.2.1. Notations et Corollaire de Cochran.

Pour tout entier  $j = 1, 2, \dots, n$ , on pose  $Z_j = \frac{X_j - \mu}{\sigma}$ .

Les variables aléatoires  $Z_1, Z_2, \dots, Z_n$  sont indépendantes et de même loi normale centrée réduite.

Ainsi, le vecteur  $Z = (Z_1, Z_2, \dots, Z_n)^T$  est un vecteur gaussien centré et de matrice de variance-covariance  $I_n$ .

On pose  $P = \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T$ , avec  $\mathbf{1}_n = (1, 1, \dots, 1)^T$ .

Il est facile de montrer que  $P$  est un projecteur orthogonal sur le sous-espace vectoriel de  $\mathbb{R}^n$  engendré par le vecteur  $\mathbf{1}_n$ . Ce sous-espace vectoriel est de dimension 1.

Ainsi en utilisant le corollaire de Cochran, on déduit que

- $\|PZ\|^2 \sim \chi_1^2$
- $\|(I_n - P)Z\|^2 \sim \chi_{n-1}^2$
- et  $\|PZ\|^2$  et  $\|(I_n - P)Z\|^2$  sont indépendants.

## 2.2.2. Fin de la preuve.

On pose  $\bar{Z}_n = \frac{1}{n} \sum_{j=1}^n Z_j$ . Il est facile de voir que  $\bar{Z}_n = \frac{\bar{X}_n - \mu}{\sigma}$  et

que  $PZ = \mathbf{1}_n \bar{Z}_n$ . On déduit alors que

$$\square \|PZ\|^2 = \|\mathbf{1}_n \bar{Z}_n\|^2 = n \bar{Z}_n^2 = \frac{n(\bar{X}_n - \mu)^2}{\sigma^2}.$$

$$\square \|(I_n - P)Z\|^2 = \|Z - \mathbf{1}_n \bar{Z}_n\|^2 = \sum_{j=1}^n (Z_j - \bar{Z}_n)^2.$$

Or, il est facile de voir que pour tout entier  $j$ , qu

$Z_j - \bar{Z}_n = \frac{X_j - \bar{X}_n}{\sigma}$ . En remplaçant alors dans le calcul de  $\|(I_n - P)Z\|^2$ , on obtient :

$$\|(I_n - P)Z\|^2 = \sum_{j=1}^n \frac{(X_j - \bar{X}_n)^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2}.$$

Ainsi, en reprenant les résultats fournis par le corollaire de Cochran, on déduit que  $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$  et  $S^2$  est indépendant de  $\bar{X}_n$ .

## 2.3. Loi de Student.

La preuve du dernier résultat repose sur le résultat de probabilité suivant :

□ Soient  $U$  et  $V$  deux variables aléatoires indépendantes.

Si  $U \sim \mathcal{N}(0, 1)$  et  $V \sim \chi_n^2$  alors  $\frac{U}{\sqrt{V/n}} \sim T_n$ .

On utilise ce résultat avec  $U = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}$  et  $V = \frac{(n-1)S^2}{\sigma^2}$ .

## 2.3. Loi de Student.

La preuve du dernier résultat repose sur le résultat de probabilité suivant :

□ Soient  $U$  et  $V$  deux variables aléatoires indépendantes.

Si  $U \sim \mathcal{N}(0, 1)$  et  $V \sim \chi_n^2$  alors  $\frac{U}{\sqrt{V/n}} \sim T_n$ .

On utilise ce résultat avec  $U = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}$  et  $V = \frac{(n-1)S^2}{\sigma^2}$ .

**En effet:** Puisque  $\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$ , alors  $\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \sim \mathcal{N}(0, 1)$ , et comme  $\bar{X}_n$  et  $S^2$  sont indépendants, il en est de même pour  $U$  et  $V$ .

ainsi, on obtient par construction le résultat souhaité :

$$\frac{\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}}{\sqrt{\frac{(n-1)S^2}{\sigma^2} / (n-1)}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{S} \sim T_{n-1}$$